

Universidad Autónoma de Santo Domingo

Primada de América | Fundada el 28 de octubre de 1538



U02.LAB04

Ciencia de Datos II

Maestro Edwin R. José Nolasco



MAESTRANTE

MANUEL DE JESUS MAÑANÁ SANTANA

INF-8239-C2

INFORME DE ENTREGA DE PROYECTO: U2.LAB004 Auditoria y Uso de un Corpus Publico

1. Enlace al Repositorio del Proyecto

- **URL del Repositorio:** https://github.com/Rickymjms/INF8239_U02_NLP_Proyecto_Base_uv.git
- **Rama Principal: main**
- **Visibilidad: Público**

INF-8239 · Unidad 02 · Proyecto NLP

Evaluación y Selección del Corpus Público (Paso 4)

Enlaces Oficiales de los Candidatos

- **Candidato 1 (Aprobado):** SetFit/amazon_reviews_multi_es (Hugging Face Datasets)
- **Candidato 2 (Descartado):** SMS Spam Collection (UCI Machine Learning Repository)

Matriz de Evaluación según Criterios y Preguntas de Aprobación

Criterio / Pregunta de aprobación	**Candidato 1 (Aprobado): Amazon Reviews Multi (es)**	**Candidato 2 (Descartado): SMS Spam Collection (UCI)**
1. Pertinencia *¿Los textos y etiquetas permiten responder la pregunta propuesta?*	**Sí.** Contiene textos de reseñas de productos en español (text / label_text) con etiquetas explícitas de sentimiento o calificación en estrellas (1 a 5), idóneas para tareas complejas de PLN.	**Parcial.** Textos breves de mensajes de texto SMS con etiquetas binarias (ham/spam). Responde a detección de spam pero no al análisis de sentimiento/opinión.
2. Licencia *¿Se permite descargar, analizar y publicar resultados derivados?*	**Sí.** Publicado bajo licencia abierta permisiva **CC-BY-4.0**. Permite libre descarga, procesamiento local, modificación y publicación de derivados.	**Sí.** Licencia pública para investigación académica atribuida al repositorio de la Universidad de California en Irvine (UCI).
3. Representatividad	**Idioma:** Español. Refleja la sintaxis y opinión escrita de usuarios en comercio electrónico. *Excluye:*	**Idioma:** Inglés. *Excluye:* Toda la población hispanohablante. Además, está sesgado a patrones

¿Qué población, idioma, periodo o grupos quedan fuera?	Lenguaje oral no estandarizado y dominios no comerciales.	de mensajería SMS informal de los años 2000.
4. Calidad *¿Hay nulos, duplicados, etiquetas ambiguas o clases extremadamente pequeñas?*	**Alta.** Clases balanceadas (mismo volumen por número de estrellas), sin nulos en el cuerpo de la reseña y con baja frecuencia de duplicados.	**Regular.** Presenta un acentuado desbalance de clases (~87% mensajes legítimos vs ~13% spam) y alto nivel de abreviaturas e informalidades.
5. Reproducibilidad *¿Otra persona puede obtener la misma versión?*	**Sí.** Accesible mediante la API de Hugging Face Datasets (SetFit/amazon_reviews_multi_es) o mediante enlace directo público sin autenticación privada.	**Sí.** Disponible de forma estática y permanente en el portal oficial de UCI Machine Learning Repository.
6. Riesgo *¿Contiene información personal, sensible o potencialmente dañina?*	**Bajo.** Comentarios de acceso público previamente anonimizados en la plataforma Amazon. No contiene datos personales identificables (PII).	**Bajo.** Corpus anonimizado de origen para fines de investigación académica.
Decisión Final	**APROBADO / SELECCIONADO**	**DESCARTADO**

Justificación Metodológica

- **Aprobación de Candidate 1 (SetFit/amazon_reviews_multi_es):** Cumple con todos los requisitos de pertinencia en español, equilibrio de clases para evitar métricas engañosas (como el accuracy aislado), licencia abierta CC-BY-4.0 y fácil integración en los contratos de validación de datos.

- **Descarte de Candidate 2 (SMS Spam Collection):** Se rechaza principalmente por estar restringido al idioma inglés, limitar el ámbito de análisis únicamente a mensajes SMS cortos binarios y presentar un marcado desbalance de clases.

Dataset

DATA_SOURCE=url
DATASET_URL=https://huggingface.co/datasets/SetFit/amazon_reviews_multi_es/raw/main/train.csv

DATASET_PATH=data/raw/amazon_reviews_es.csv

TEXT_COLUMN=review_body

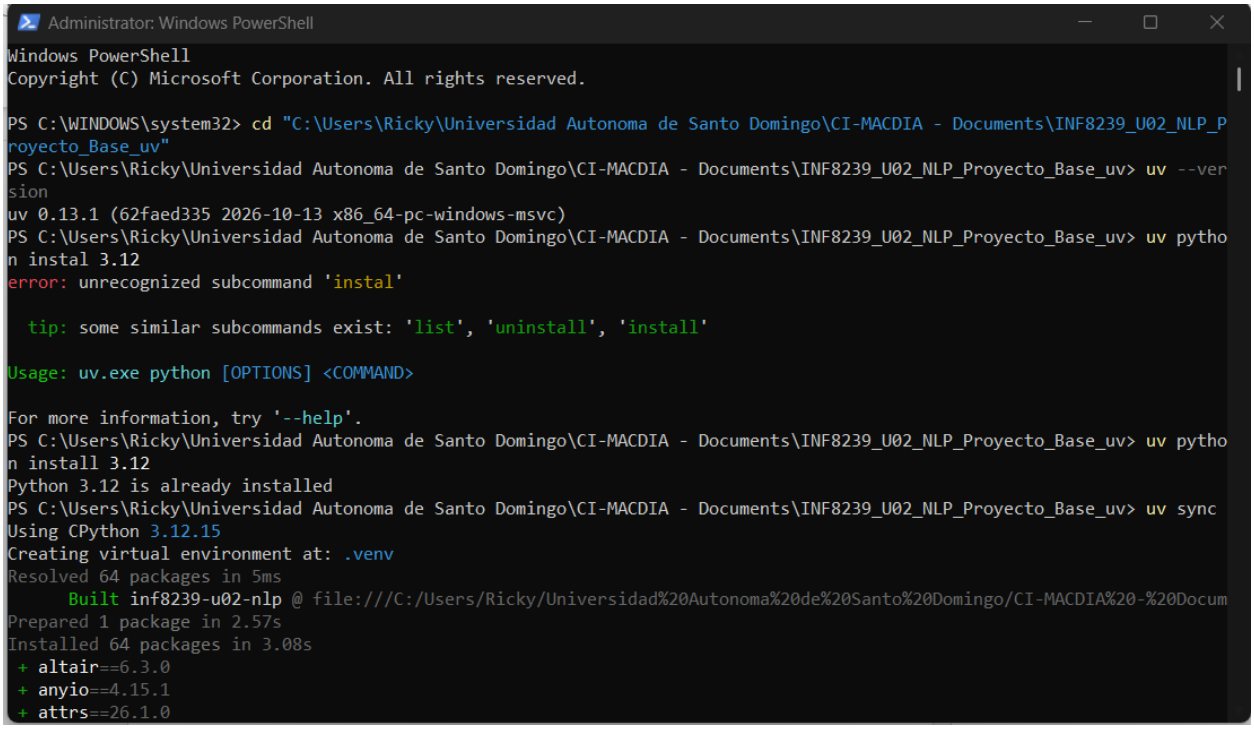
TARGET_COLUMN=stars

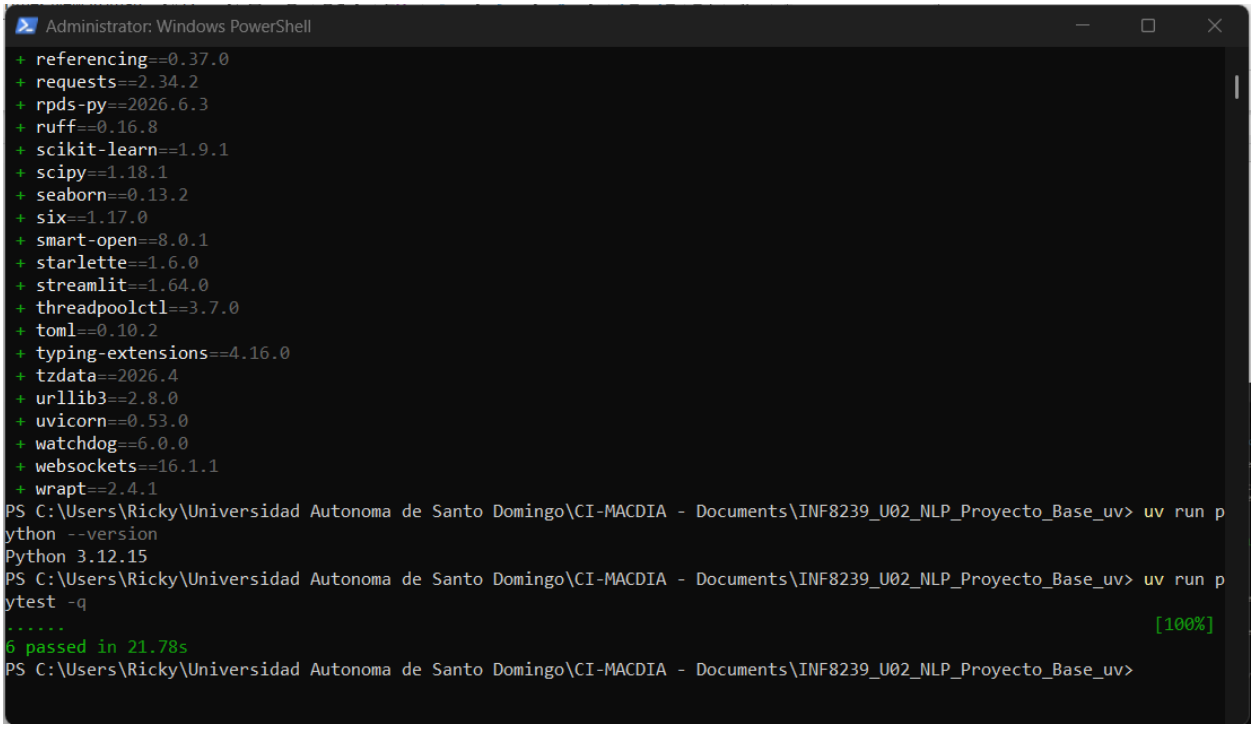
Complete docs/DATASET_CARD.md, el diccionario de datos (docs/dataset_candidates.csv), la licencia y el procedimiento de obtención. El archivo data/sample/demo_text.csv solamente comprueba la arquitectura.

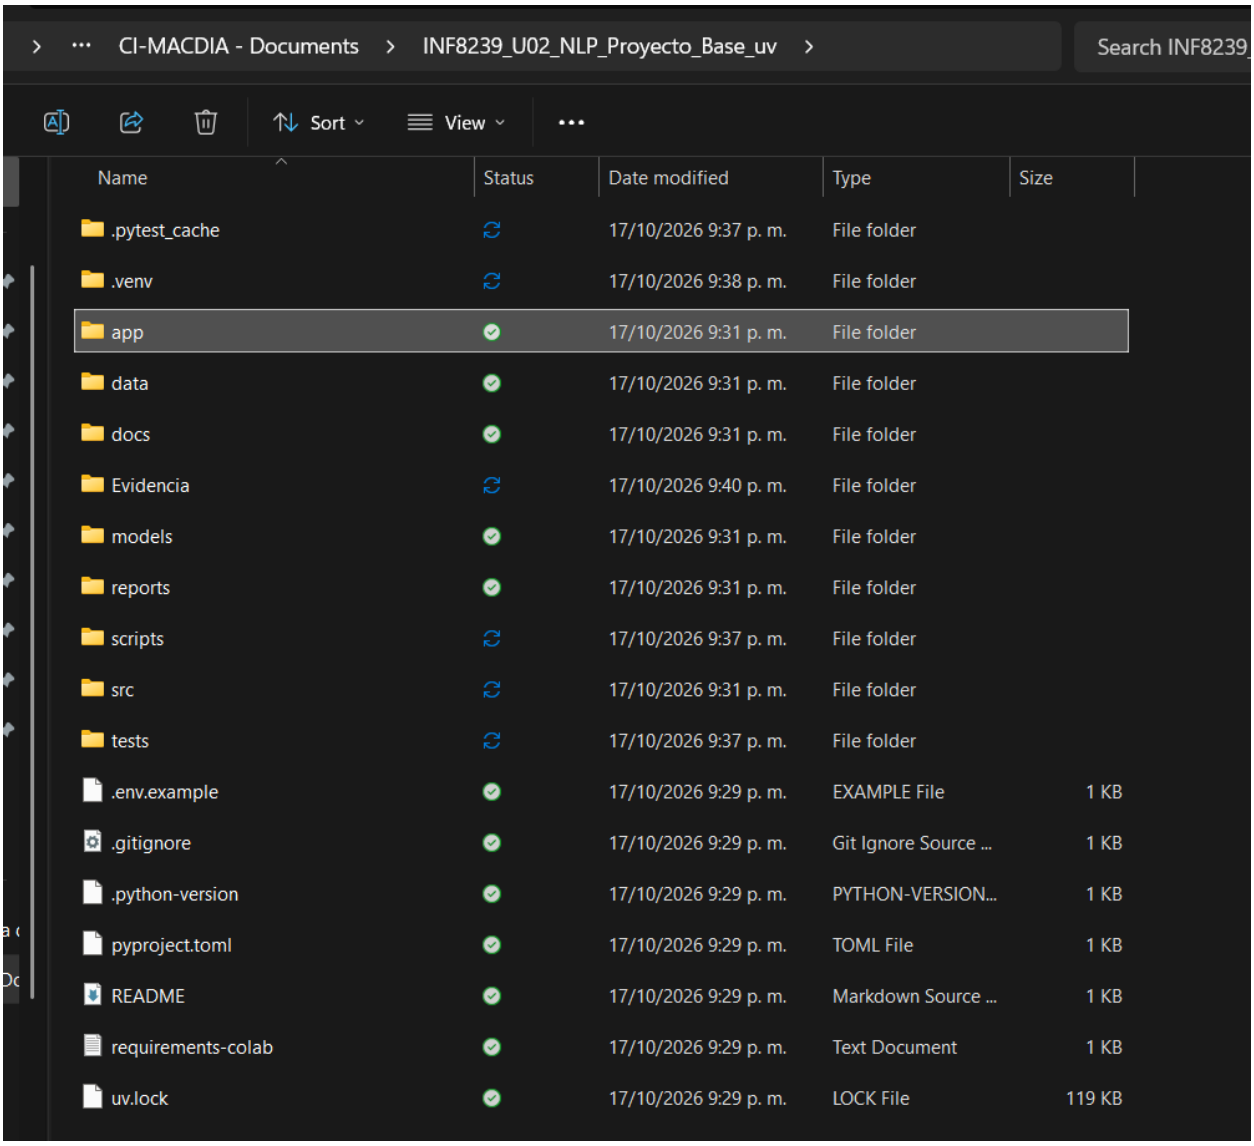
Entrenamiento

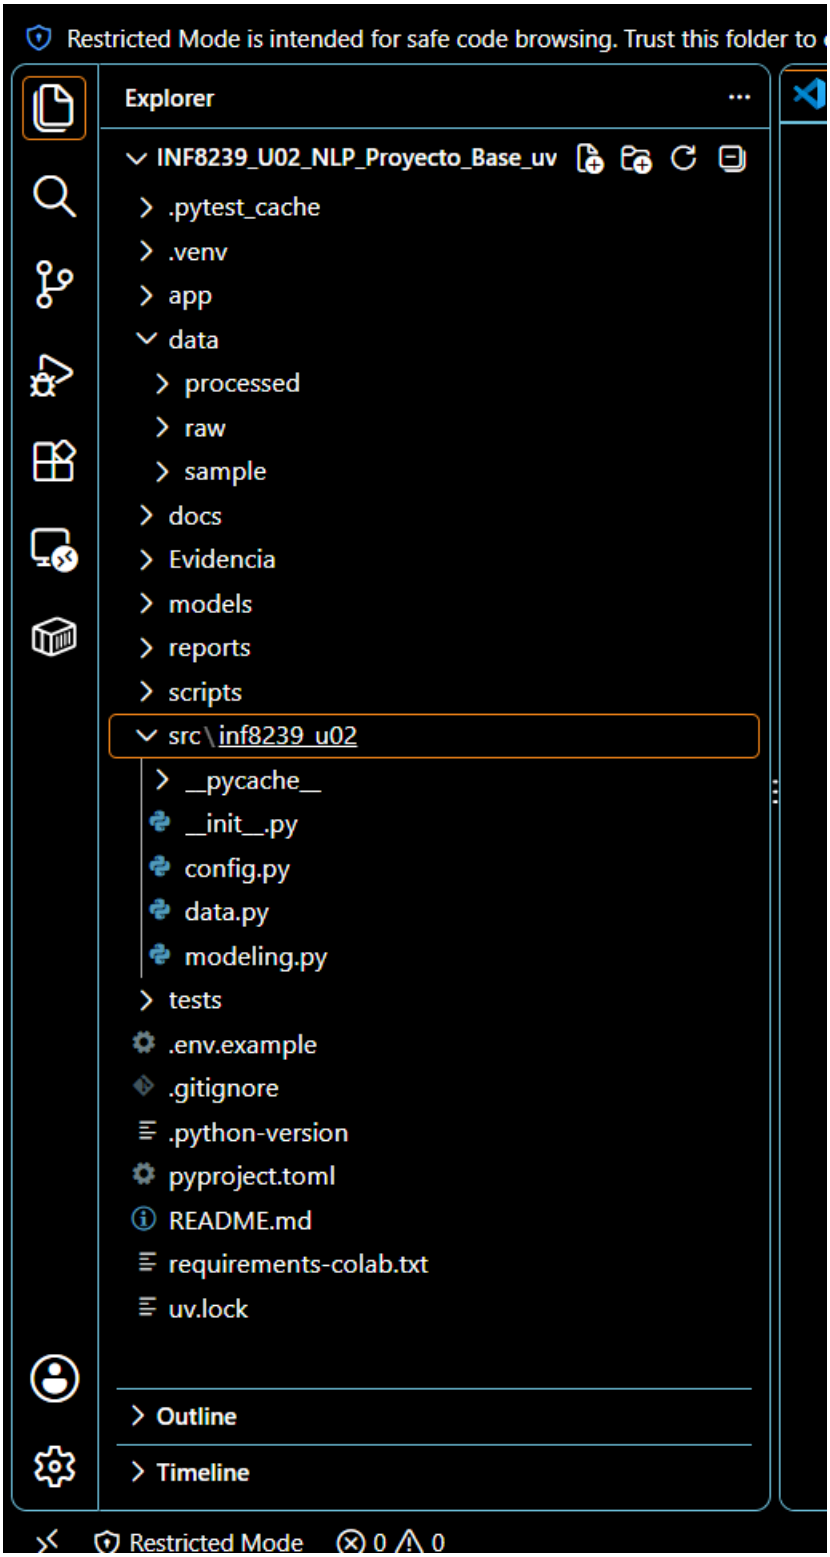
uv run python scripts/train_text.py

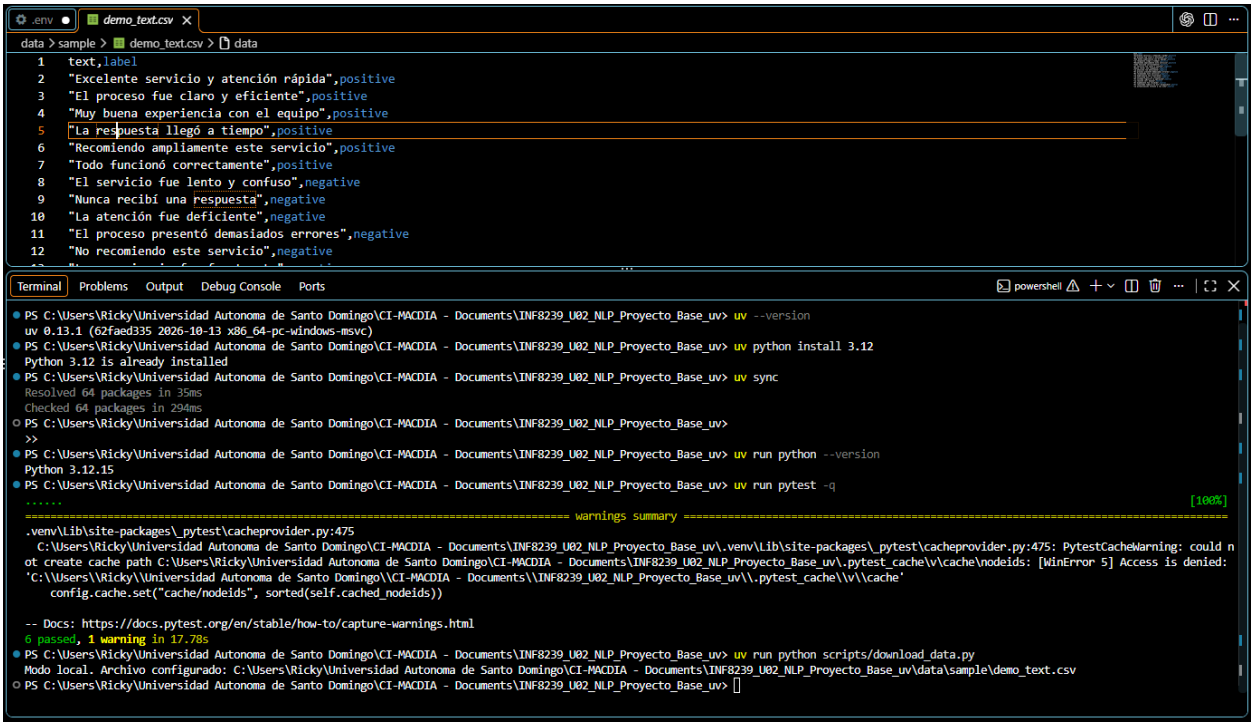
uv run streamlit run app/streamlit_app.py

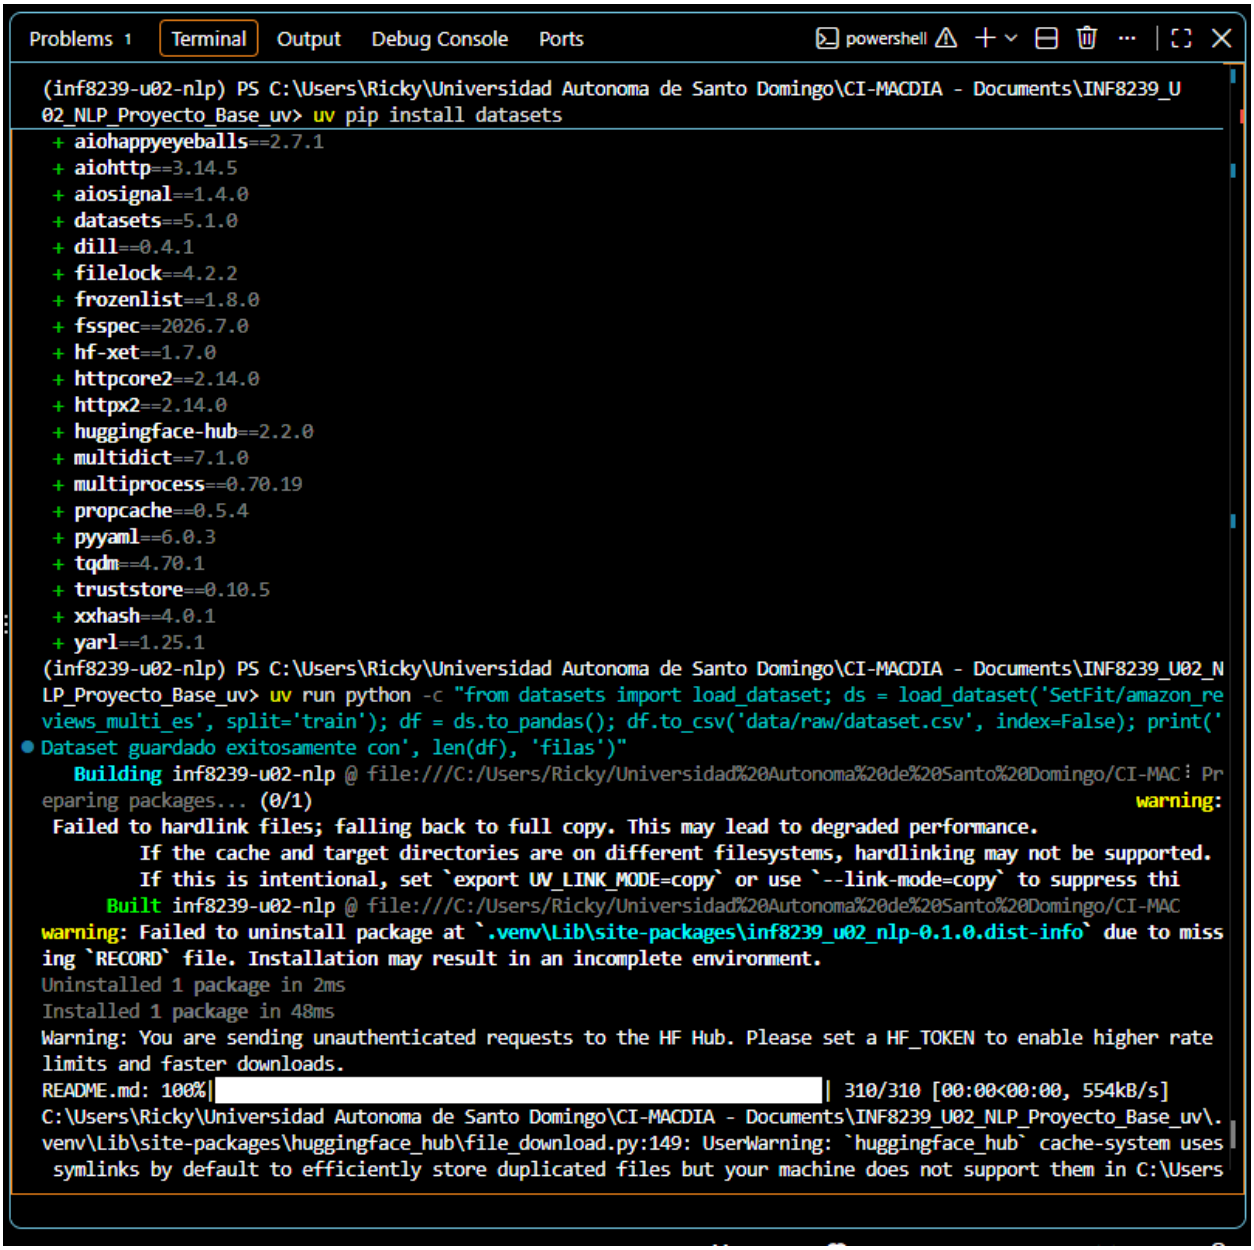

Administrator: Windows PowerShell
Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.
PS C:\WINDOWS\system32> cd "C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv"
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv --version
uv 0.13.1 (62faed335 2026-10-13 x86_64-pc-windows-msvc)
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv python instal 3.12
error: unrecognized subcommand 'instal'
tip: some similar subcommands exist: 'list', 'uninstall', 'install'
Usage: uv.exe python [OPTIONS] <COMMAND>
For more information, try '--help'.
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv python install 3.12
Python 3.12 is already installed
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv sync
Using CPython 3.12.15
Creating virtual environment at: .venv
Resolved 64 packages in 5ms
Built inf8239-u02-nlp @ file:///C:/Users/Ricky/Universidad%20Autonoma%20de%20Santo%20Domingo/CI-MACDIA%20-%20Docum
Prepared 1 package in 2.57s
Installed 64 packages in 3.08s
+ altair==6.3.0
+ anyio==4.15.1
+ attrs==26.1.0

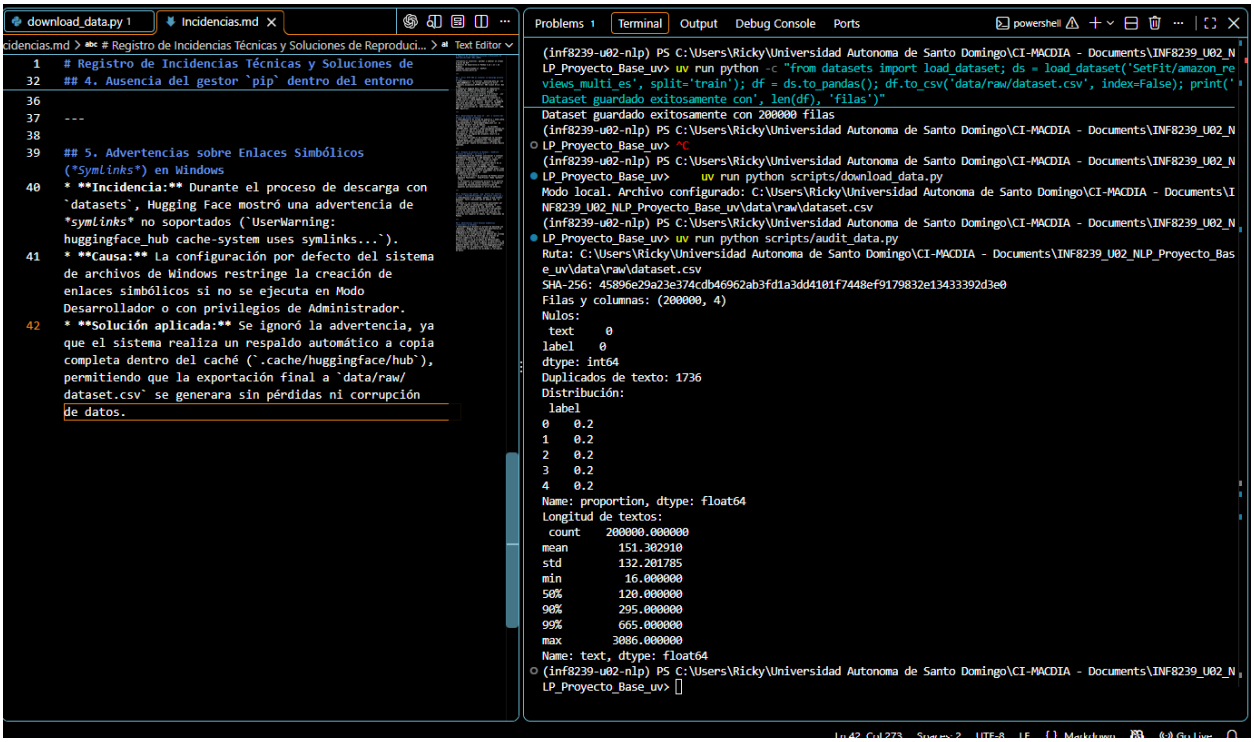

Administrator: Windows PowerShell
+ referencing==0.37.0
+ requests==2.34.2
+ rpds-py==2026.6.3
+ ruff==0.16.8
+ scikit-learn==1.9.1
+ scipy==1.18.1
+ seaborn==0.13.2
+ six==1.17.0
+ smart-open==8.0.1
+ starlette==1.6.0
+ streamlit==1.64.0
+ threadpoolctl==3.7.0
+ toml==0.10.2
+ typing-extensions==4.16.0
+ tzdata==2026.4
+ urllib3==2.8.0
+ uvicorn==0.53.0
+ watchdog==6.0.0
+ websockets==16.1.1
+ wrapt==2.4.1
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python --version
Python 3.12.15
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run pytest -q
...... [100%]
6 passed in 21.78s
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>

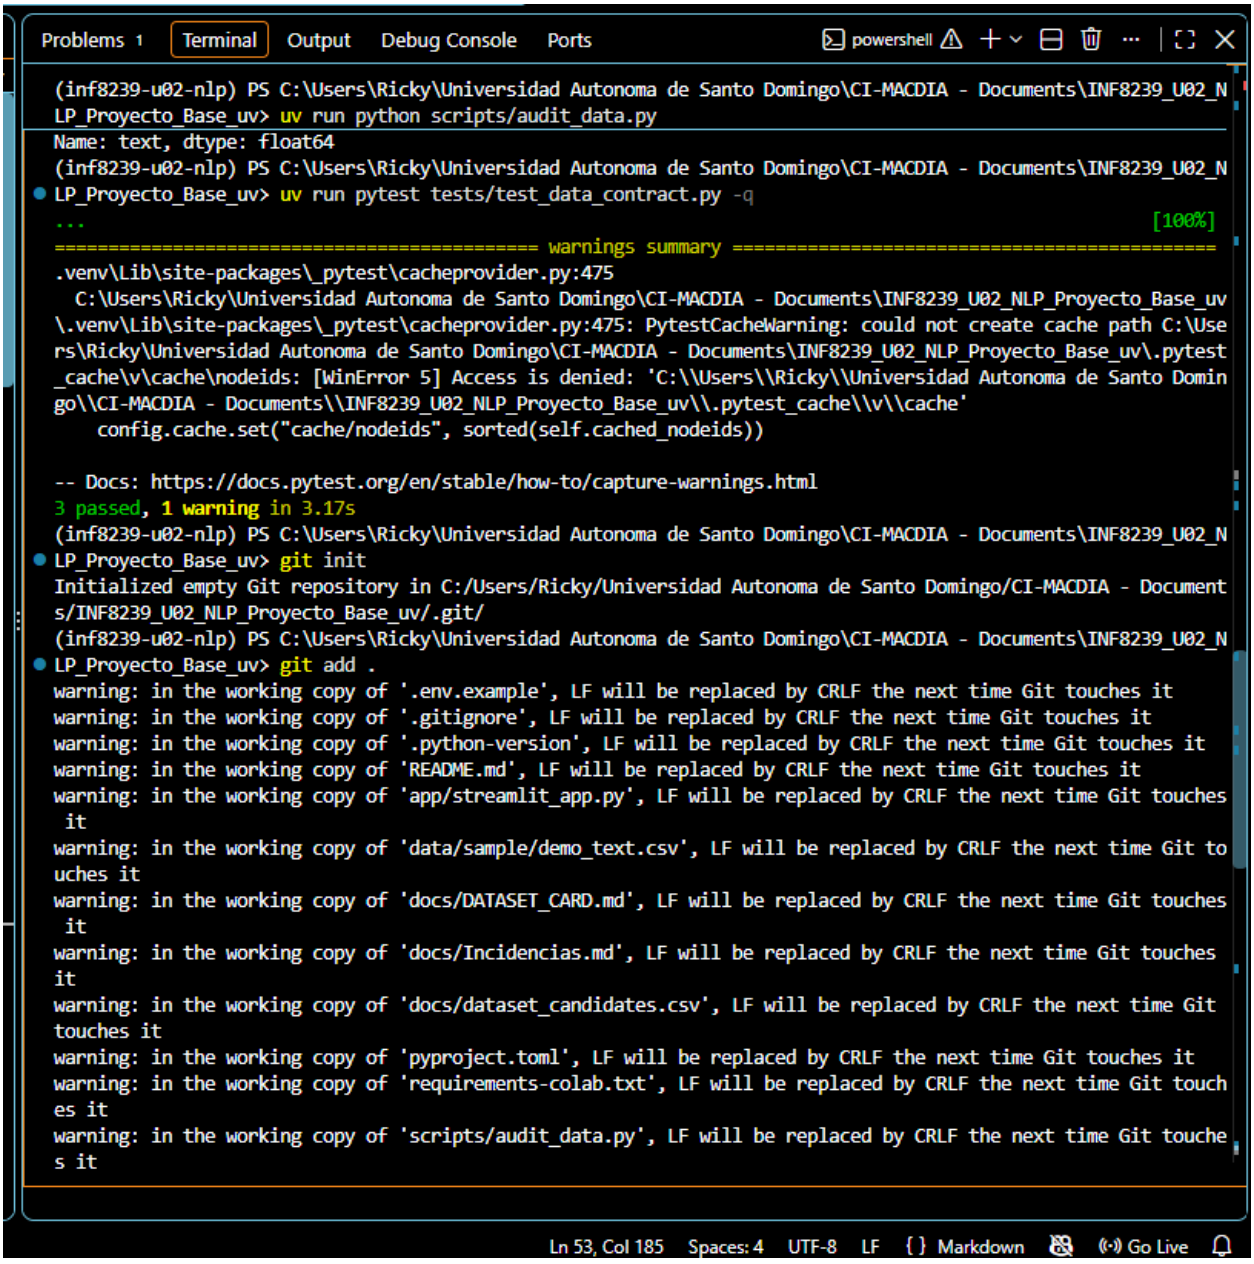

CI-MACDIA - Documents
INF8239_U02_NLP_Proyecto_Base_uv
Search INF8239
Sort
View
Name
Status
Date modified
Type
Size
.pytest_cache 17/10/2026 9:37 p. m. File folder
.venv 17/10/2026 9:38 p. m. File folder
app 17/10/2026 9:31 p. m. File folder
data 17/10/2026 9:31 p. m. File folder
docs 17/10/2026 9:31 p. m. File folder
Evidencia 17/10/2026 9:40 p. m. File folder
models 17/10/2026 9:31 p. m. File folder
reports 17/10/2026 9:31 p. m. File folder
scripts 17/10/2026 9:37 p. m. File folder
src 17/10/2026 9:31 p. m. File folder
tests 17/10/2026 9:37 p. m. File folder
.env.example 17/10/2026 9:29 p. m. EXAMPLE File 1 KB
.gitignore 17/10/2026 9:29 p. m. Git Ignore Source ... 1 KB
.python-version 17/10/2026 9:29 p. m. PYTHON-VERSION... 1 KB
pyproject.toml 17/10/2026 9:29 p. m. TOML File 1 KB
README 17/10/2026 9:29 p. m. Markdown Source ... 1 KB
requirements-colab 17/10/2026 9:29 p. m. Text Document 1 KB
uv.lock 17/10/2026 9:29 p. m. LOCK File 119 KB

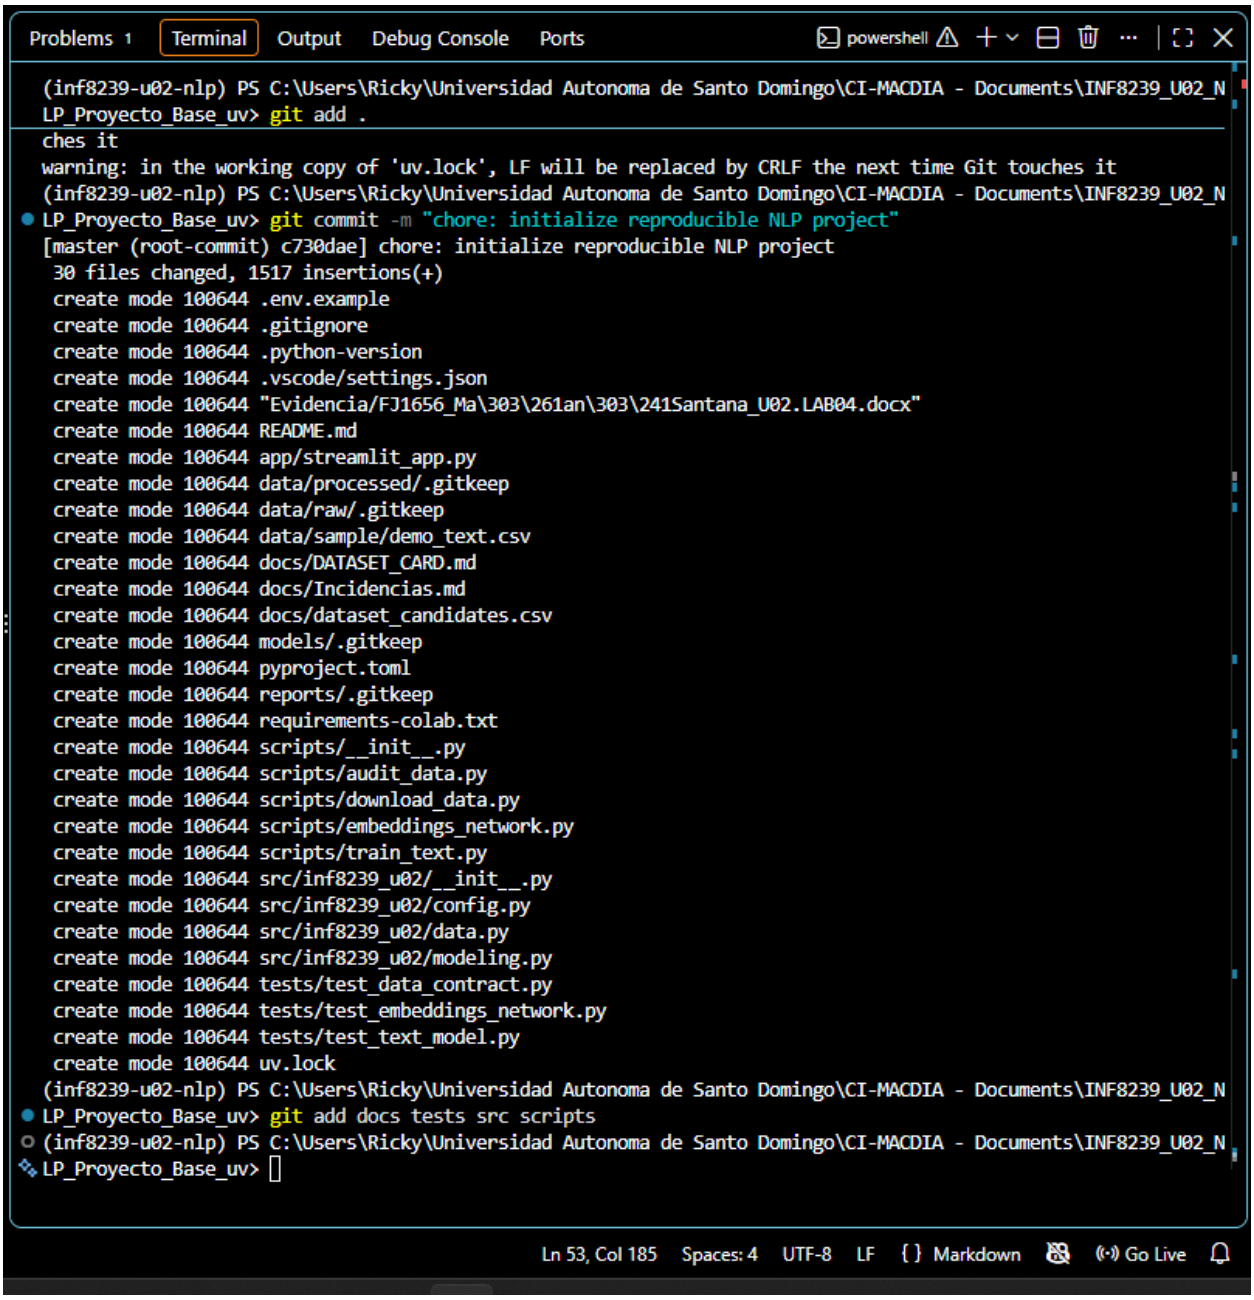

Restricted Mode is intended for safe code browsing. Trust this folder to
Explorer
INF8239_U02_NLP_Proyecto_Base_uv
.pytest_cache
.venv
app
data
processed
raw
sample
docs
Evidencia
models
reports
scripts
src\inf8239_u02
__pycache__
__init__.py
config.py
data.py
modeling.py
tests
.env.example
.gitignore
.python-version
pyproject.toml
README.md
requirements-colab.txt
uv.lock
Outline
Timeline
Restricted Mode
0
0

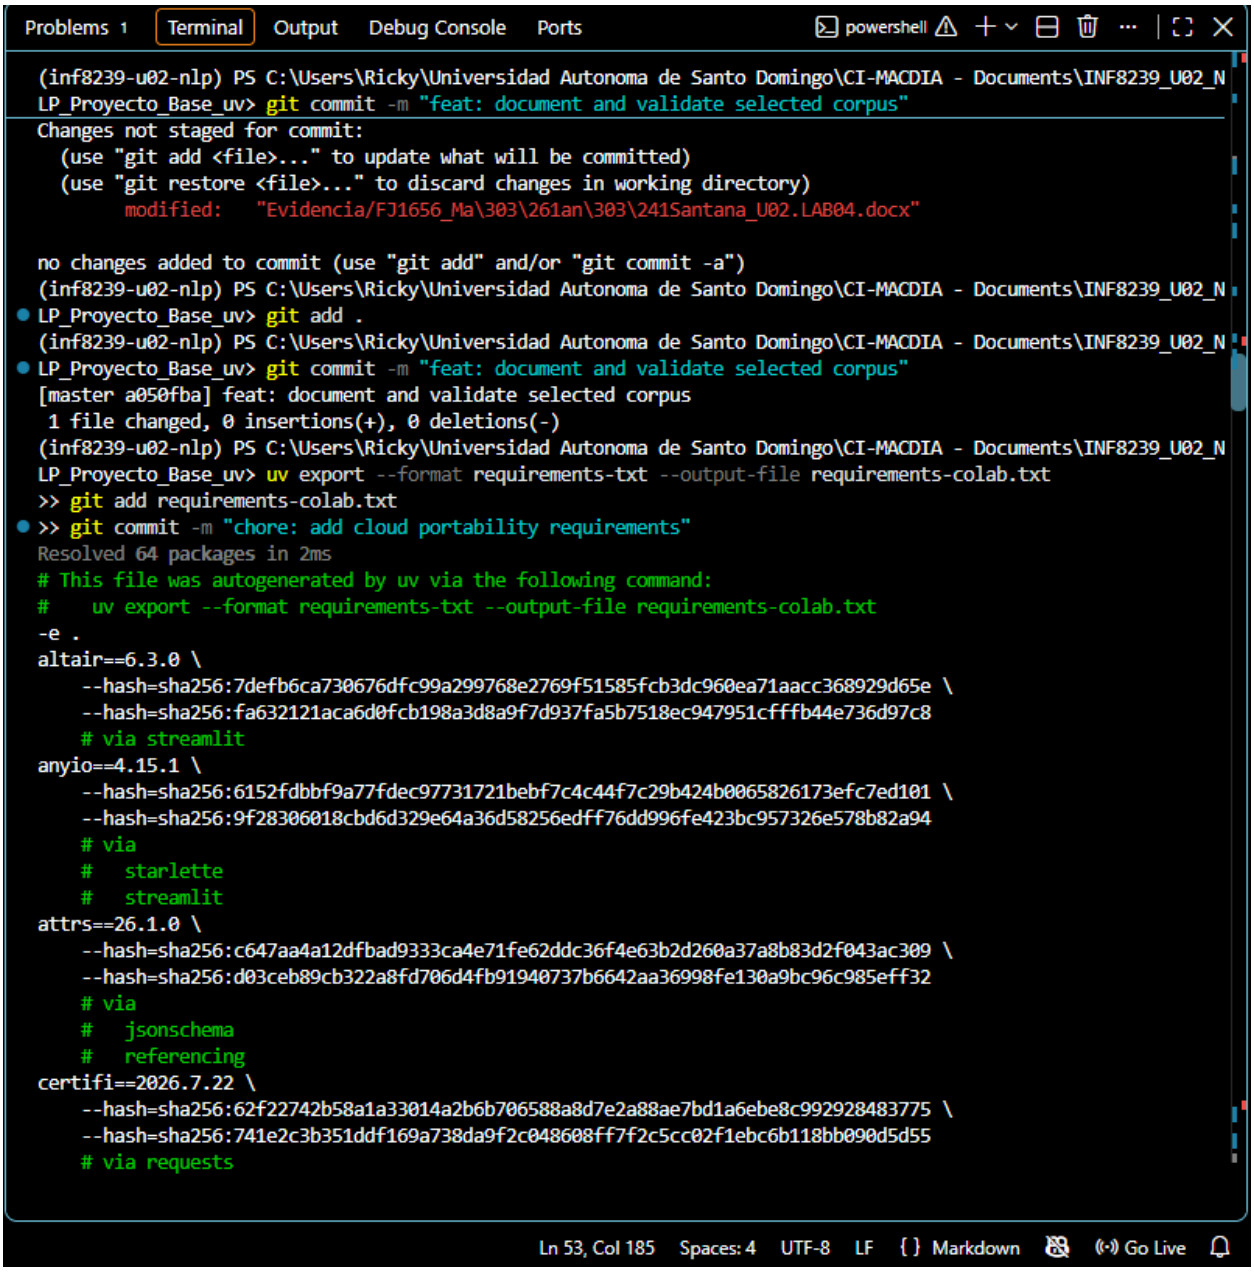

.env
demo_text.csv
data > sample > demo_text.csv > data
1 text,label
2 "Excelente servicio y atención rápida",positive
3 "El proceso fue claro y eficiente",positive
4 "Muy buena experiencia con el equipo",positive
5 "La respuesta llegó a tiempo",positive
6 "Recomiendo ampliamente este servicio",positive
7 "Todo funcionó correctamente",positive
8 "El servicio fue lento y confuso",negative
9 "Nunca recibí una respuesta",negative
10 "La atención fue deficiente",negative
11 "El proceso presentó demasiados errores",negative
12 "No recomiendo este servicio",negative
Terminal
Problems
Output
Debug Console
Ports
powershell
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv --version
uv 0.13.1 (62faed335 2026-10-13 x86_64-pc-windows-msvc)
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv python install 3.12
Python 3.12 is already installed
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv sync
Resolved 64 packages in 35ms
Checked 64 packages in 294ms
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
>>
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python --version
Python 3.12.15
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run pytest -q
[100%]
warnings summary
.venv\Lib\site-packages_pytest\cacheprovider.py:475
C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.venv\Lib\site-packages_pytest\cacheprovider.py:475: PytestCacheWarning: could not create cache path C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.pytest_cache\v\cache\nodeids: [WinError 5] Access is denied: 'C:\\Users\\Ricky\\Universidad Autonoma de Santo Domingo\\CI-MACDIA - Documents\\INF8239_U02_NLP_Proyecto_Base_uv\\.pytest_cache\\v\\cache'
config.cache.set("cache/nodeids", sorted(self.cached_nodeids))
-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
6 passed, 1 warning in 17.78s
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python scripts/download_data.py
Modo local. Archivo configurado: C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\data\sample\demo_text.csv
PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>


Problems 1
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv pip install datasets
+ aiohappyeyeballs==2.7.1
+ aiohttp==3.14.5
+ aiosignal==1.4.0
+ datasets==5.1.0
+ dill==0.4.1
+ filelock==4.2.2
+ frozenlist==1.8.0
+ fsspec==2026.7.0
+ hf-xet==1.7.0
+ httpcore2==2.14.0
+ httpx2==2.14.0
+ huggingface-hub==2.2.0
+ multidict==7.1.0
+ multiprocess==0.70.19
+ propcache==0.5.4
+ pyyaml==6.0.3
+ tqdm==4.70.1
+ truststore==0.10.5
+ xxhash==4.0.1
+ yarl==1.25.1
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python -c "from datasets import load_dataset; ds = load_dataset('SetFit/amazon_reviews_multi_es', split='train'); df = ds.to_pandas(); df.to_csv('data/raw/dataset.csv', index=False); print('Dataset guardado exitosamente con', len(df), 'filas')"
Building inf8239-u02-nlp @ file:///C:/Users/Ricky/Universidad%20Autonoma%20de%20Santo%20Domingo/CI-MAC
Preparing packages... (0/1)
warning: Failed to hardlink files; falling back to full copy. This may lead to degraded performance.
If the cache and target directories are on different filesystems, hardlinking may not be supported.
If this is intentional, set `export UV_LINK_MODE=copy` or use `--link-mode=copy` to suppress thi
Built inf8239-u02-nlp @ file:///C:/Users/Ricky/Universidad%20Autonoma%20de%20Santo%20Domingo/CI-MAC
warning: Failed to uninstall package at `.venv\Lib\site-packages\inf8239_u02_nlp-0.1.0.dist-info` due to missing `RECORD` file. Installation may result in an incomplete environment.
Uninstalled 1 package in 2ms
Installed 1 package in 48ms
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
README.md: 100%| 310/310 [00:00<00:00, 554kB/s]
C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.venv\Lib\site-packages\huggingface_hub\file_download.py:149: UserWarning: `huggingface_hub` cache-system uses symlinks by default to efficiently store duplicated files but your machine does not support them in C:\Users


download_data.py 1
Incidencias.md
cidencias.md > # Registro de Incidencias Técnicas y Soluciones de Reproduci... > Text Editor
1 # Registro de Incidencias Técnicas y Soluciones de
32 ## 4. Ausencia del gestor `pip` dentro del entorno
36
37 ---
38
39 ## 5. Advertencias sobre Enlaces Simbólicos
(*Symlinks*) en Windows
40 * **Incidencia:** Durante el proceso de descarga con
`datasets`, Hugging Face mostró una advertencia de
symlinks no soportados (`UserWarning:
huggingface_hub cache-system uses symlinks...`).
41 * **Causa:** La configuración por defecto del sistema
de archivos de Windows restringe la creación de
enlaces simbólicos si no se ejecuta en Modo
Desarrollador o con privilegios de Administrador.
42 * **Solución aplicada:** Se ignoró la advertencia, ya
que el sistema realiza un respaldo automático a copia
completa dentro del caché (`.cache/huggingface/hub`),
permitiendo que la exportación final a `data/raw/
dataset.csv` se generara sin pérdidas ni corrupción
de datos.
Problems 1
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_N
LP_Proyecto_Base_uv> uv run python -c "from datasets import load_dataset; ds = load_dataset('SetFit/amazon_re
views_multi_es', split='train'); df = ds.to_pandas(); df.to_csv('data/raw/dataset.csv', index=False); print('
Dataset guardado exitosamente con', len(df), 'filas')"
Dataset guardado exitosamente con 200000 filas
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_N
LP_Proyecto_Base_uv> ^C
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_N
LP_Proyecto_Base_uv> uv run python scripts/download_data.py
Modo local. Archivo configurado: C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\I
NF8239_U02_NLP_Proyecto_Base_uv\data\raw\dataset.csv
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_N
LP_Proyecto_Base_uv> uv run python scripts/audit_data.py
Ruta: C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Bas
e_uv\data\raw\dataset.csv
SHA-256: 45896e29a23e374cdb46962ab3fd1a3dd4101f7448ef9179832e13433392d3e0
Filas y columnas: (200000, 4)
Nulos:
text 0
label 0
dtype: int64
Duplicados de texto: 1736
Distribución:
label
0 0.2
1 0.2
2 0.2
3 0.2
4 0.2
Name: proportion, dtype: float64
Longitud de textos:
count 200000.000000
mean 151.302910
std 132.201785
min 16.000000
50% 120.000000
90% 295.000000
99% 665.000000
max 3086.000000
Name: text, dtype: float64
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_N
LP_Proyecto_Base_uv>


Problems 1
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python scripts/audit_data.py
Name: text, dtype: float64
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run pytest tests/test_data_contract.py -q
... [100%]
warnings summary
.venv\Lib\site-packages_pytest\cacheprovider.py:475
C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.venv\Lib\site-packages_pytest\cacheprovider.py:475: PytestCacheWarning: could not create cache path C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.pytest_cache\v\cache\nodeids: [WinError 5] Access is denied: 'C:\\Users\\Ricky\\Universidad Autonoma de Santo Domingo\\CI-MACDIA - Documents\\INF8239_U02_NLP_Proyecto_Base_uv\\.pytest_cache\\v\\cache'
config.cache.set("cache/nodeids", sorted(self.cached_nodeids))
-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
3 passed, 1 warning in 3.17s
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git init
Initialized empty Git repository in C:/Users/Ricky/Universidad Autonoma de Santo Domingo/CI-MACDIA - Documents/INF8239_U02_NLP_Proyecto_Base_uv/.git/
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git add .
warning: in the working copy of '.env.example', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of '.gitignore', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of '.python-version', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'README.md', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'app/streamlit_app.py', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'data/sample/demo_text.csv', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'docs/DATASET_CARD.md', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'docs/Incidencias.md', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'docs/dataset_candidates.csv', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'pyproject.toml', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'requirements-colab.txt', LF will be replaced by CRLF the next time Git touches it
warning: in the working copy of 'scripts/audit_data.py', LF will be replaced by CRLF the next time Git touches it
Ln 53, Col 185
Spaces: 4
UTF-8
LF
{} Markdown
Go Live


Problems 1
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git add .
ches it
warning: in the working copy of 'uv.lock', LF will be replaced by CRLF the next time Git touches it
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git commit -m "chore: initialize reproducible NLP project"
[master (root-commit) c730dae] chore: initialize reproducible NLP project
30 files changed, 1517 insertions(+)
create mode 100644 .env.example
create mode 100644 .gitignore
create mode 100644 .python-version
create mode 100644 .vscode/settings.json
create mode 100644 "Evidencia/FJ1656_Ma\303\261an\303\241Santana_U02.LAB04.docx"
create mode 100644 README.md
create mode 100644 app/streamlit_app.py
create mode 100644 data/processed/.gitkeep
create mode 100644 data/raw/.gitkeep
create mode 100644 data/sample/demo_text.csv
create mode 100644 docs/DATASET_CARD.md
create mode 100644 docs/Incidencias.md
create mode 100644 docs/dataset_candidates.csv
create mode 100644 models/.gitkeep
create mode 100644 pyproject.toml
create mode 100644 reports/.gitkeep
create mode 100644 requirements-colab.txt
create mode 100644 scripts/__init__.py
create mode 100644 scripts/audit_data.py
create mode 100644 scripts/download_data.py
create mode 100644 scripts/embeddings_network.py
create mode 100644 scripts/train_text.py
create mode 100644 src/inf8239_u02/__init__.py
create mode 100644 src/inf8239_u02/config.py
create mode 100644 src/inf8239_u02/data.py
create mode 100644 src/inf8239_u02/modeling.py
create mode 100644 tests/test_data_contract.py
create mode 100644 tests/test_embeddings_network.py
create mode 100644 tests/test_text_model.py
create mode 100644 uv.lock
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git add docs tests src scripts
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
Ln 53, Col 185
Spaces: 4
UTF-8
LF
{ } Markdown
Go Live


Problems 1
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git commit -m "feat: document and validate selected corpus"
Changes not staged for commit:
(use "git add <file>..." to update what will be committed)
(use "git restore <file>..." to discard changes in working directory)
modified: "Evidencia/FJ1656_Ma\303\261an\303\241Santana_U02.LAB04.docx"
no changes added to commit (use "git add" and/or "git commit -a")
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git add .
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> git commit -m "feat: document and validate selected corpus"
[master a050fba] feat: document and validate selected corpus
1 file changed, 0 insertions(+), 0 deletions(-)
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv export --format requirements-txt --output-file requirements-colab.txt
>> git add requirements-colab.txt
>> git commit -m "chore: add cloud portability requirements"
Resolved 64 packages in 2ms
This file was autogenerated by uv via the following command:
uv export --format requirements-txt --output-file requirements-colab.txt
-e .
altair==6.3.0 \
--hash=sha256:7defb6ca730676dfc99a299768e2769f51585fcb3dc960ea71aacc368929d65e \
--hash=sha256:fa632121aca6d0fcb198a3d8a9f7d937fa5b7518ec947951cfffb44e736d97c8
via streamlit
anyio==4.15.1 \
--hash=sha256:6152fdbbf9a77fdec97731721bebf7c4c44f7c29b424b0065826173efc7ed101 \
--hash=sha256:9f28306018cbd6d329e64a36d58256edff76dd996fe423bc957326e578b82a94
via
starlette
streamlit
attrs==26.1.0 \
--hash=sha256:c647aa4a12dfbad9333ca4e71fe62ddc36f4e63b2d260a37a8b83d2f043ac309 \
--hash=sha256:d03ceb89cb322a8fd706d4fb91940737b6642aa36998fe130a9bc96c985eff32
via
jsonschema
referencing
certifi==2026.7.22 \
--hash=sha256:62f22742b58a1a33014a2b6b706588a8d7e2a88ae7bd1a6ebe8c992928483775 \
--hash=sha256:741e2c3b351ddf169a738da9f2c048608ff7f2c5cc02f1ebc6b118bb090d5d55
via requests
Ln 53, Col 185
Spaces: 4
UTF-8
LF
{ } Markdown
Go Live

Registro de Incidencias Técnicas y Soluciones de Reproducibilidad (LAB04)

1. Error 404 en descarga HTTP directa desde Hugging Face

- **Problema:** El intento de descarga mediante URL pública directa (requests.get) a la ruta original de amazon_reviews_multi falló con un error HTTP 404 Client Error: Not Found. Esto se debió a la deprecación/reubicación interna de ciertos subconjuntos en Hugging Face y la migración masiva de datasets a formato Parquet.
- **Impacto:** Impedía que el script estándar scripts/download_data.py obtuviera el archivo .csv crudo vía HTTP directo.
- **Solución y Decisión de Arquitectura:** En lugar de depender de enlaces HTTP estáticos propensos a cambios de ruta, se configuró el entorno en **Modo Local** (DATA_SOURCE=local en .env) y se utilizó la librería oficial de Python datasets de Hugging Face para descargar el *split* de entrenamiento (train) de SetFit/amazon_reviews_multi_es, convirtiéndolo e independizándolo localmente en data/raw/dataset.csv.

2. Inconsistencia de rutas en .env y fallback al dataset de prueba

- **Problema:** En el archivo .env la variable DATASET_PATH apuntaba a data/raw/amazon_reviews_es.csv, mientras que el script download_data.py generaba por defecto el archivo en data/raw/dataset.csv.
- **Impacto:** Al no encontrar el archivo en la ruta declarada en el .env, el script de auditoría (audit_data.py) recurría automáticamente al conjunto de demostración en data/sample/demo_text.csv (18 filas).
- **Solución:** Se estandarizó la variable en .env especificando explícitamente DATASET_PATH=data/raw/dataset.csv, alineando la ruta configurada con el archivo real descargado.

3. Bloqueo de archivos en Windows / OneDrive (Access is denied - os error 5)

- **Problema:** Al ejecutar comandos de gestión de dependencias como uv add datasets o uv sync, se presentó el error Access is denied (os error 5) al intentar eliminar o reescribir la carpeta de metadatos .venv\Lib\site-packages\inf8239_u02_nlp-0.1.0.dist-info.
- **Impacto:** Ocurrió por estar trabajando sobre un directorio sincronizado por **Microsoft OneDrive** y por procesos de Python en segundo plano (como el servidor de lenguaje Pylance en VS Code) que mantenían bloqueados los archivos del entorno virtual .venv.
- **Solución:**
    1. Se forzó la liberación de procesos en PowerShell mediante Stop-Process -Name "python*" -Force.

2. Se instaló la dependencia usando la herramienta de administración directa de paquetes uv pip install datasets, evitando que uv intentara desinstalar o reconstruir el paquete local en conflicto.
3. Como alternativa de ejecución aislada sin modificar el entorno cargado, se validó el uso de inyección dinámica de dependencias mediante uv run --with datasets ....

4. Ausencia del módulo pip en entornos ligeros de uv (ModuleNotFoundError: No module named pip)

- **Problema:** Al intentar ejecutar python -m pip install datasets, el intérprete devolvió No module named pip.
- **Impacto:** Los entornos virtuales gestionados por uv se crean de forma optimizada y minimalista, omitiendo la instalación por defecto de pip dentro de .venv.
- **Solución:** Se utilizó el gestor de paquetes integrado de uv ejecutando el comando uv pip install datasets, permitiendo la instalación en la carpeta del entorno virtual.

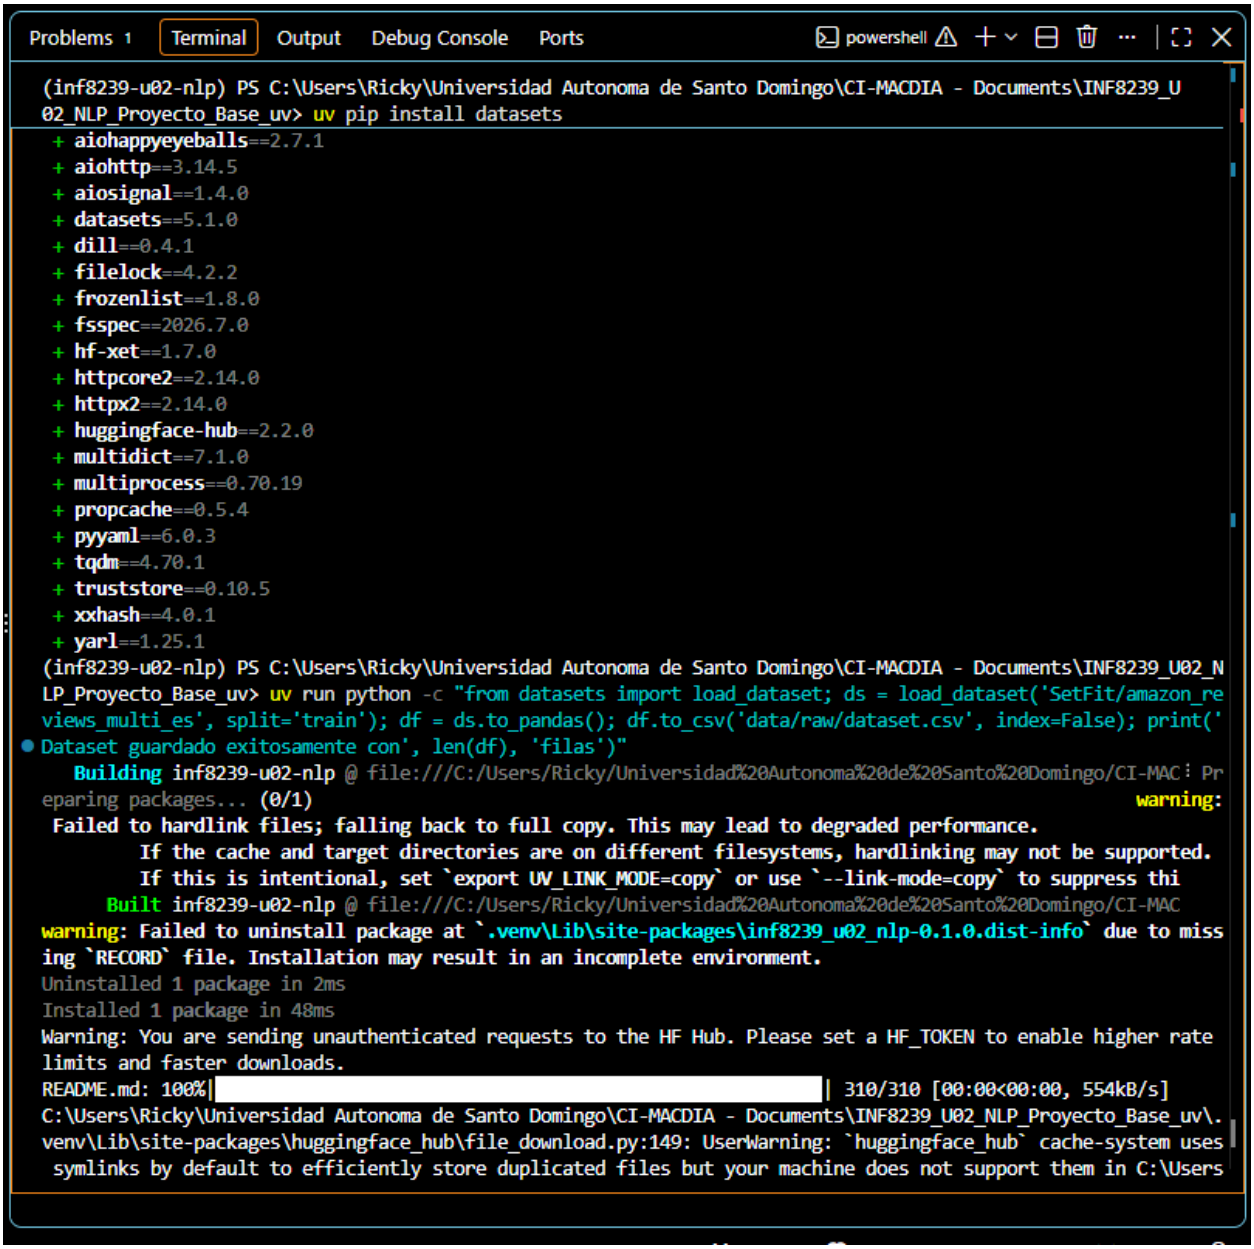
5. Advertencia de symlinks en el caché de Hugging Face (Windows)

- **Problema:** Durante la descarga del corpus, la librería huggingface_hub emitió una advertencia (UserWarning) indicando que el sistema de archivos de Windows no tenía activado el soporte de enlaces simbólicos (*symlinks*).
- **Solución:** La descarga continuó correctamente almacenando los datos mediante copia completa en la memoria caché (.cache/huggingface/hub), lo cual no compromete la integridad del archivo exportado a data/raw/dataset.csv.

Declaración de uso de Inteligencia Artificial

Durante el desarrollo de este proyecto analítico y la redacción del reporte técnico correspondiente al laboratorio **U02.LAB04: Desde cero: localizar, aprobar y auditar un corpus público**, se utilizó una herramienta de asistencia basada en Inteligencia Artificial como recurso de apoyo consultivo. Su uso se limitó a la clarificación de conceptos sobre reproducibilidad y auditoría de datos de PLN, orientación en la estructuración de la Ficha Técnica (*Dataset Card*) y el diccionario de variables, apoyo en la configuración de entornos aislados con uv y control de versiones con Git, así como en la revisión formal del informe.

El autor ha ejecutado, verificado y validado de forma autónoma la totalidad de la descarga e independización local del dataset, el cálculo del Hash SHA-256, los análisis estadísticos de auditoría de datos, la aprobación de las pruebas de contrato con pytest y las conclusiones metodológicas expuestas, asumiendo la plena y exclusiva responsabilidad sobre el contenido final del entregable.


Problems 1
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv pip install datasets
+ aiohappyeyeballs==2.7.1
+ aiohttp==3.14.5
+ aiosignal==1.4.0
+ datasets==5.1.0
+ dill==0.4.1
+ filelock==4.2.2
+ frozenlist==1.8.0
+ fsspec==2026.7.0
+ hf-xet==1.7.0
+ httpcore2==2.14.0
+ httpx2==2.14.0
+ huggingface-hub==2.2.0
+ multidict==7.1.0
+ multiprocess==0.70.19
+ propcache==0.5.4
+ pyyaml==6.0.3
+ tqdm==4.70.1
+ truststore==0.10.5
+ xxhash==4.0.1
+ yarl==1.25.1
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python -c "from datasets import load_dataset; ds = load_dataset('SetFit/amazon_reviews_multi_es', split='train'); df = ds.to_pandas(); df.to_csv('data/raw/dataset.csv', index=False); print('Dataset guardado exitosamente con', len(df), 'filas')"
Building inf8239-u02-nlp @ file:///C:/Users/Ricky/Universidad%20Autonoma%20de%20Santo%20Domingo/CI-MAC
Preparing packages... (0/1)
warning: Failed to hardlink files; falling back to full copy. This may lead to degraded performance.
If the cache and target directories are on different filesystems, hardlinking may not be supported.
If this is intentional, set `export UV_LINK_MODE=copy` or use `--link-mode=copy` to suppress thi
Built inf8239-u02-nlp @ file:///C:/Users/Ricky/Universidad%20Autonoma%20de%20Santo%20Domingo/CI-MAC
warning: Failed to uninstall package at `.venv\Lib\site-packages\inf8239_u02_nlp-0.1.0.dist-info` due to missing `RECORD` file. Installation may result in an incomplete environment.
Uninstalled 1 package in 2ms
Installed 1 package in 48ms
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
README.md: 100%| 310/310 [00:00<00:00, 554kB/s]
C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.venv\Lib\site-packages\huggingface_hub\file_download.py:149: UserWarning: `huggingface_hub` cache-system uses symlinks by default to efficiently store duplicated files but your machine does not support them in C:\Users