

Universidad Autónoma de Santo Domingo

Primada de América | Fundada el 28 de octubre de 1538



U02.LAB05

Ciencia de Datos II

Maestro Edwin R. José Nolasco



MAESTRANTE

MANUEL DE JESUS MAÑANÁ SANTANA

INF-8239-C2

INFORME DE ENTREGA DE PROYECTO: U2.LAB005

Clasificación de texto: TF-IDF, Naive Bayes y modelo lineal

1. Enlace al Repositorio del Proyecto

- **URL del Repositorio:** https://github.com/Rickymjms/INF8239_U02_NLP_Proyecto_Base_uv.git
- **Rama Principal: main**
- **Visibilidad: Público**

INF-8239 · Unidad 02 · Proyecto NLP

Enlaces Oficiales del datasets

- SetFit/amazon_reviews_multi_es (Hugging Face Datasets)

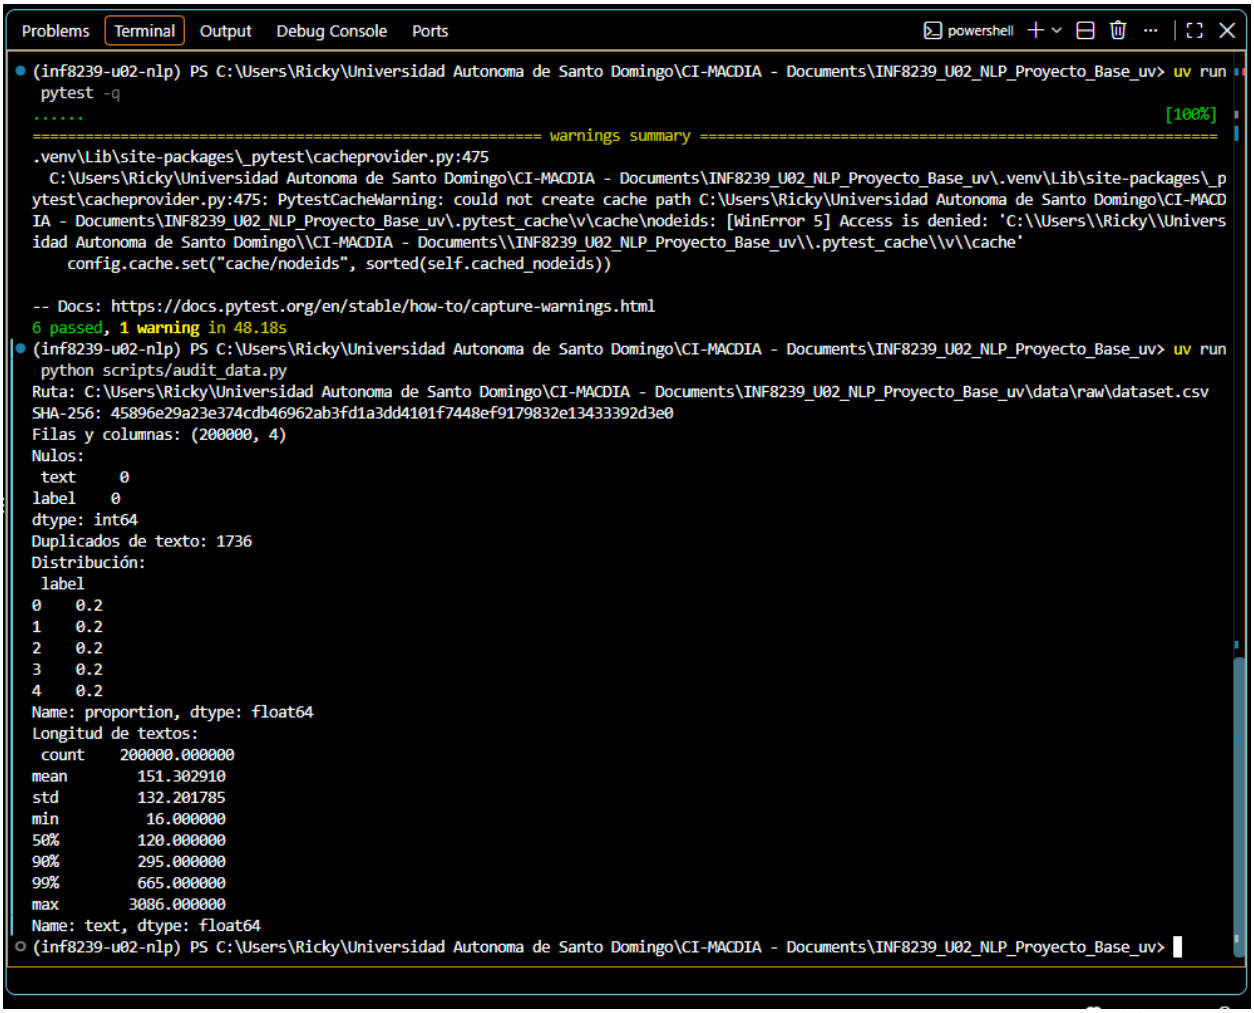
Matriz de Evaluación según Criterios y Preguntas de Aprobación

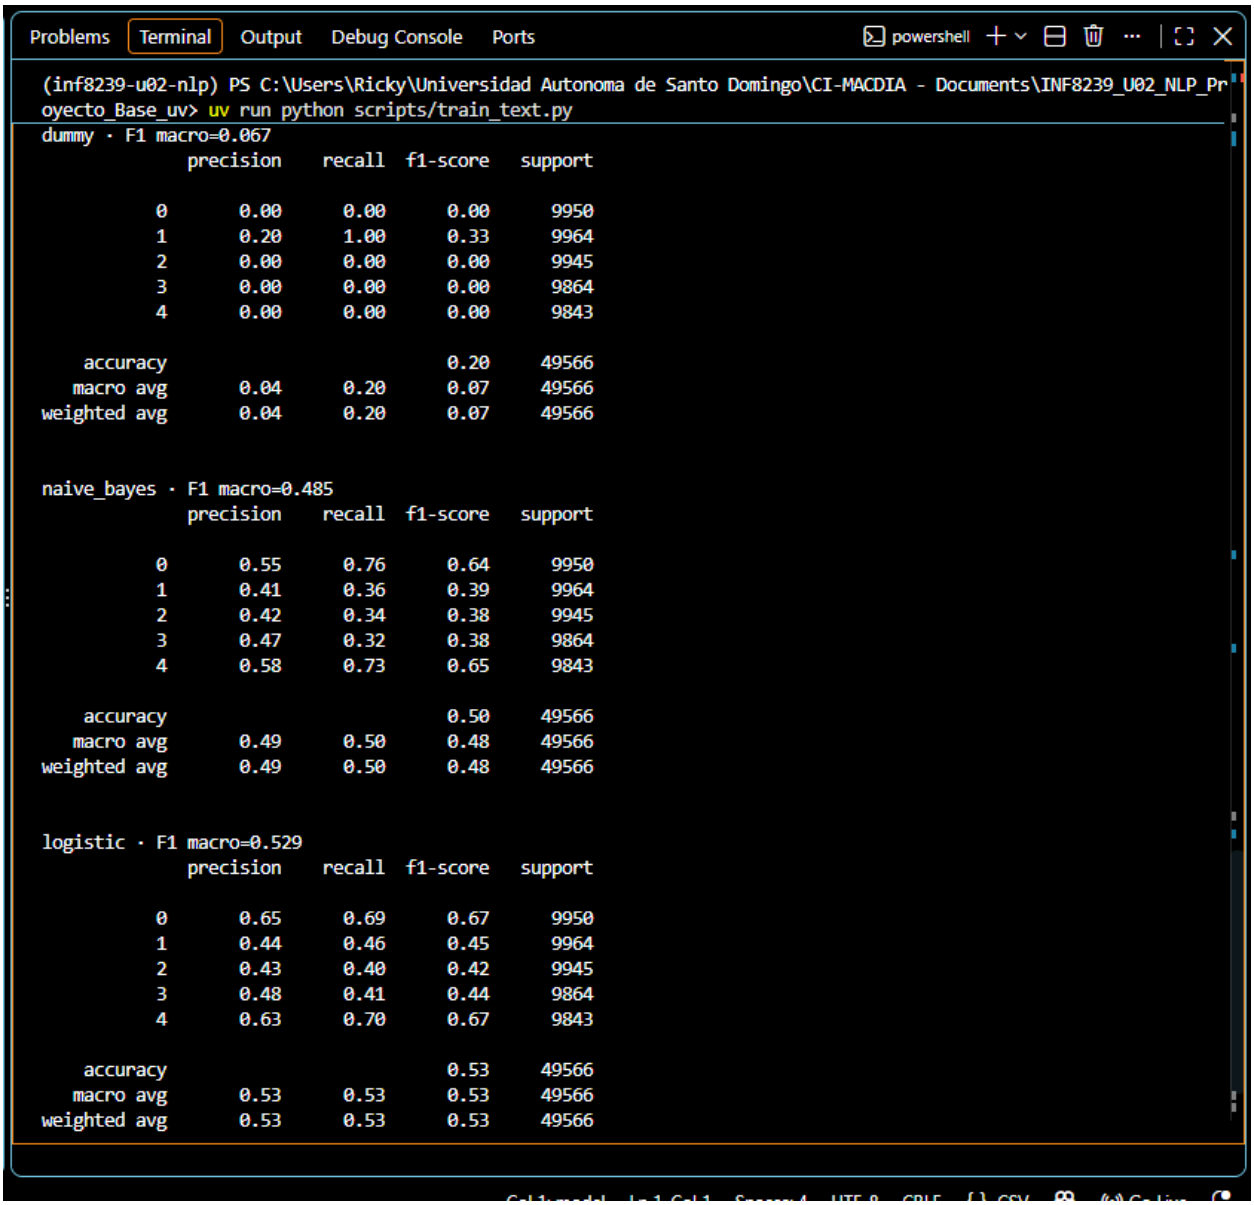
Criterio / Pregunta de aprobación	**Candidato 1 (Aprobado): Amazon Reviews Multi (es)**
1. Pertinencia *¿Los textos y etiquetas permiten responder la pregunta propuesta?*	**Sí.** Contiene textos de reseñas de productos en español (text / label_text) con etiquetas explícitas de sentimiento o calificación en estrellas (1 a 5), idóneas para tareas complejas de PLN.
2. Licencia *¿Se permite descargar, analizar y publicar resultados derivados?*	**Sí.** Publicado bajo licencia abierta permisiva **CC-BY-4.0**. Permite libre descarga, procesamiento local, modificación y publicación de derivados.
3. Representatividad *¿Qué población, idioma, periodo o grupos quedan fuera?*	**Idioma:** Español. Refleja la sintaxis y opinión escrita de usuarios en comercio electrónico. *Excluye:* Lenguaje oral no estandarizado y dominios no comerciales.
4. Calidad	

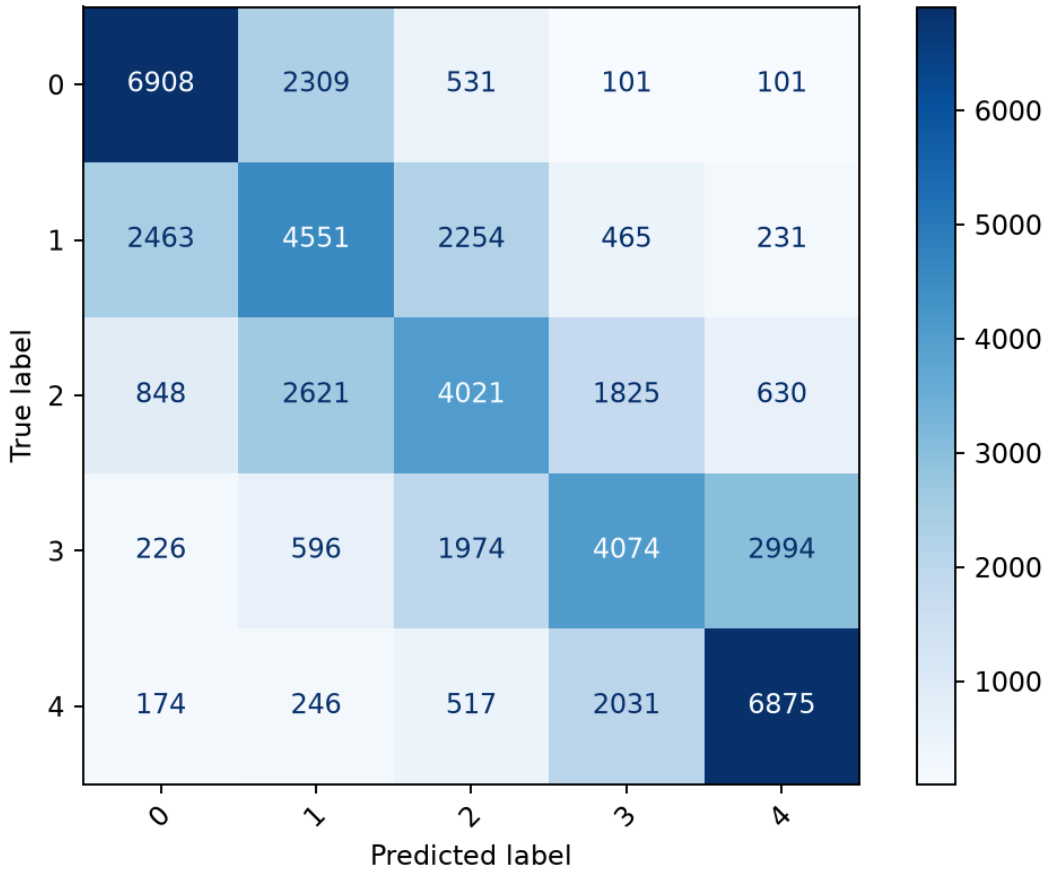
¿Hay nulos, duplicados, etiquetas ambiguas o clases extremadamente pequeñas?	**Alta.** Clases balanceadas (mismo volumen por número de estrellas), sin nulos en el cuerpo de la reseña y con baja frecuencia de duplicados.
5. Reproducibilidad	**Sí.** Accesible mediante la API de Hugging Face Datasets (SetFit/amazon_reviews_multi_es) o mediante enlace directo público sin autenticación privada.
¿Otra persona puede obtener la misma versión?	
6. Riesgo	**Bajo.** Comentarios de acceso público previamente anonimizados en la plataforma Amazon. No contiene datos personales identificables (PII).
¿Contiene información personal, sensible o potencialmente dañina?	
Decisión Final	**APROBADO / SELECCIONADO**

Justificación Metodológica

- **(SetFit/amazon_reviews_multi_es):** Cumple con todos los requisitos de pertinencia en español, equilibrio de clases para evitar métricas engañosas (como el accuracy aislado), licencia abierta CC-BY-4.0 y fácil integración en los contratos de validación de datos.


Problems
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run pytest -q
[100%]
warnings summary
.venv\Lib\site-packages_pytest\cacheprovider.py:475
C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.venv\Lib\site-packages_pytest\cacheprovider.py:475: PytestCacheWarning: could not create cache path C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.pytest_cache\v\cache\nodeids: [WinError 5] Access is denied: 'C:\\Users\\Ricky\\Universidad Autonoma de Santo Domingo\\CI-MACDIA - Documents\\INF8239_U02_NLP_Proyecto_Base_uv\\.pytest_cache\\v\\cache'
config.cache.set("cache/nodeids", sorted(self.cached_nodeids))
-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
6 passed, 1 warning in 48.18s
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python scripts/audit_data.py
Ruta: C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\data\raw\dataset.csv
SHA-256: 45896e29a23e374cdb46962ab3fd1a3dd4101f7448ef9179832e13433392d3e0
Filas y columnas: (200000, 4)
Nulos:
text 0
label 0
dtype: int64
Duplicados de texto: 1736
Distribución:
label
0 0.2
1 0.2
2 0.2
3 0.2
4 0.2
Name: proportion, dtype: float64
Longitud de textos:
count 200000.000000
mean 151.302910
std 132.201785
min 16.000000
50% 120.000000
90% 295.000000
99% 665.000000
max 3086.000000
Name: text, dtype: float64
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>


Problems
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv> uv run python scripts/train_text.py
dummy · F1 macro=0.067
precision recall f1-score support
0 0.00 0.00 0.00 9950
1 0.20 1.00 0.33 9964
2 0.00 0.00 0.00 9945
3 0.00 0.00 0.00 9864
4 0.00 0.00 0.00 9843
accuracy 0.20 49566
macro avg 0.04 0.20 0.07 49566
weighted avg 0.04 0.20 0.07 49566
naive_bayes · F1 macro=0.485
precision recall f1-score support
0 0.55 0.76 0.64 9950
1 0.41 0.36 0.39 9964
2 0.42 0.34 0.38 9945
3 0.47 0.32 0.38 9864
4 0.58 0.73 0.65 9843
accuracy 0.50 49566
macro avg 0.49 0.50 0.48 49566
weighted avg 0.49 0.50 0.48 49566
logistic · F1 macro=0.529
precision recall f1-score support
0 0.65 0.69 0.67 9950
1 0.44 0.46 0.45 9964
2 0.43 0.40 0.42 9945
3 0.48 0.41 0.44 9864
4 0.63 0.70 0.67 9843
accuracy 0.53 49566
macro avg 0.53 0.53 0.53 49566
weighted avg 0.53 0.53 0.53 49566



Análisis e Interpretación de Métricas (U02.LAB05)

1. Respuestas a las preguntas de evaluación

Pregunta	Respuesta analítica	Evidencia de los resultados
¿Supera el baseline?	**Sí, de forma contundente.** La Regresión Logística alcanza un F1 macro de **0.529**, superando por **+0.462** puntos al baseline (DummyClassifier, F1 macro = 0.067) y por **+0.044** a Naive Bayes (0.485). La ganancia en capacidad predictiva justifica la complejidad del pipeline con TF-IDF.	dummy: 0.067 naive_bayes: 0.485 logistic: **0.529**
¿Qué clase se pierde?	**La clase 2 (calificaciones neutras / 3 estrellas).** Registra la exhaustividad (*recall*) más baja con solo **0.404 (40.4%)**, dejando un saldo de **5,924 falsos negativos**. La matriz de confusión confirma que se confunde frecuentemente con las clases adyacentes 1 (2,621 casos) y 3 (1,825 casos).	Fila 2 de la matriz: Aciertos (TP): **4,021**

		Falsos Negativos (FN): **5,924**
¿Qué predicción es poco confiable?	**Las predicciones asignadas a las clases 1 y 2.** La clase 2 presenta la menor precisión (**0.433 / 43.3%**) con **5,276 falsos positivos**, mientras que la clase 1 registra una precisión de **0.441 (44.1%)** con **5,772 falsos positivos**. Más del 55% de los textos etiquetados por el modelo en estas categorías pertenecen en realidad a otra clase.	Columna 2 (FP = 5,276)
		Columna 1 (FP = 5,772)
¿Existe desbalance?	**No en la distribución de prueba.** El soporte (*support*) por clase es uniforme, con aproximadamente 9,900 ejemplos por categoría (distribución balanceada al 20% por clase). Por ello, el *accuracy* global (**0.53**) coincide con el F1 macro (**0.529**).	Support por clase:
		Clase 0: 9,950
		Clase 1: 9,964
		Clase 2: 9,945
		Clase 3: 9,864
		Clase 4: 9,843
¿Puede generalizar?	**Limitado al dominio original.** La capacidad predictiva aplica exclusivamente a reseñas de productos escritas en español en plataformas de comercio electrónico. No garantiza desempeño adecuado en español dominicano informal, tuits, contratos legales ni textos médicos.	Dominio: E-commerce (Amazon Reviews Multi ES)

2. Modelo de explicación completado

La regresión logística obtuvo el mejor F1 macro (0.529). Sin embargo, la clase 2 presentó el menor recall (0.404 / 40.4%), con 5,924 falsos negativos. En este contexto ese error implica que la gran mayoría de las opiniones neutras o de satisfacción intermedia son clasificadas erróneamente como valoraciones decididamente negativas (clase 1) o positivas (clase 3), perdiendo la capacidad de detectar insatisfacciones moderadas de los usuarios. Por ello proponemos un ajuste de ponderación de clases, la inclusión de n-gramas más extensos o la consolidación de umbrales de decisión antes de publicar.

Inspección de la Matriz de Confusión (reports/confusion_text.png)

1. Visualización y lectura de la matriz

Al abrir la imagen generada en reports/confusion_text.png, la matriz relaciona las etiquetas reales (*True label*, filas) contra las etiquetas predichas (*Predicted label*, columnas) para las 5 categorías de estrellas (0 a 4).

2. Identificación de la diagonal principal (Aciertos)

La diagonal principal muestra el número total de predicciones correctas (*True Positives*) para cada clase:

- **Clase 0 (1 estrella):** 6,908 aciertos.

- **Clase 1 (2 estrellas):** 4,551 aciertos.
- **Clase 2 (3 estrellas - Neutro):** 4,021 aciertos.
- **Clase 3 (4 estrellas):** 4,074 aciertos.
- **Clase 4 (5 estrellas):** 6,875 aciertos.

Observación: Las clases extremas (0 y 4) concentran la mayor precisión diagnóstica del modelo, mientras que las clases intermedias (1, 2 y 3) presentan mayor dispersión.

3. Celda fuera de la diagonal con mayor frecuencia

La celda fuera de la diagonal con la frecuencia más alta se encuentra en:

- **Fila 3 (Clase Real = 3) / Columna 4 (Clase Predicha = 4)** con **2,994 casos**.

(Seguida muy de cerca por Fila 2 / Columna 1 con 2,621 casos).

4. Explicación del costo real en un entorno operativo

Esta confusión no es un simple margen de error numérico; representa una **falla de matiz de alta relevancia de negocio**:

1. **Invisibilización de alertas tempranas y críticas menores:**

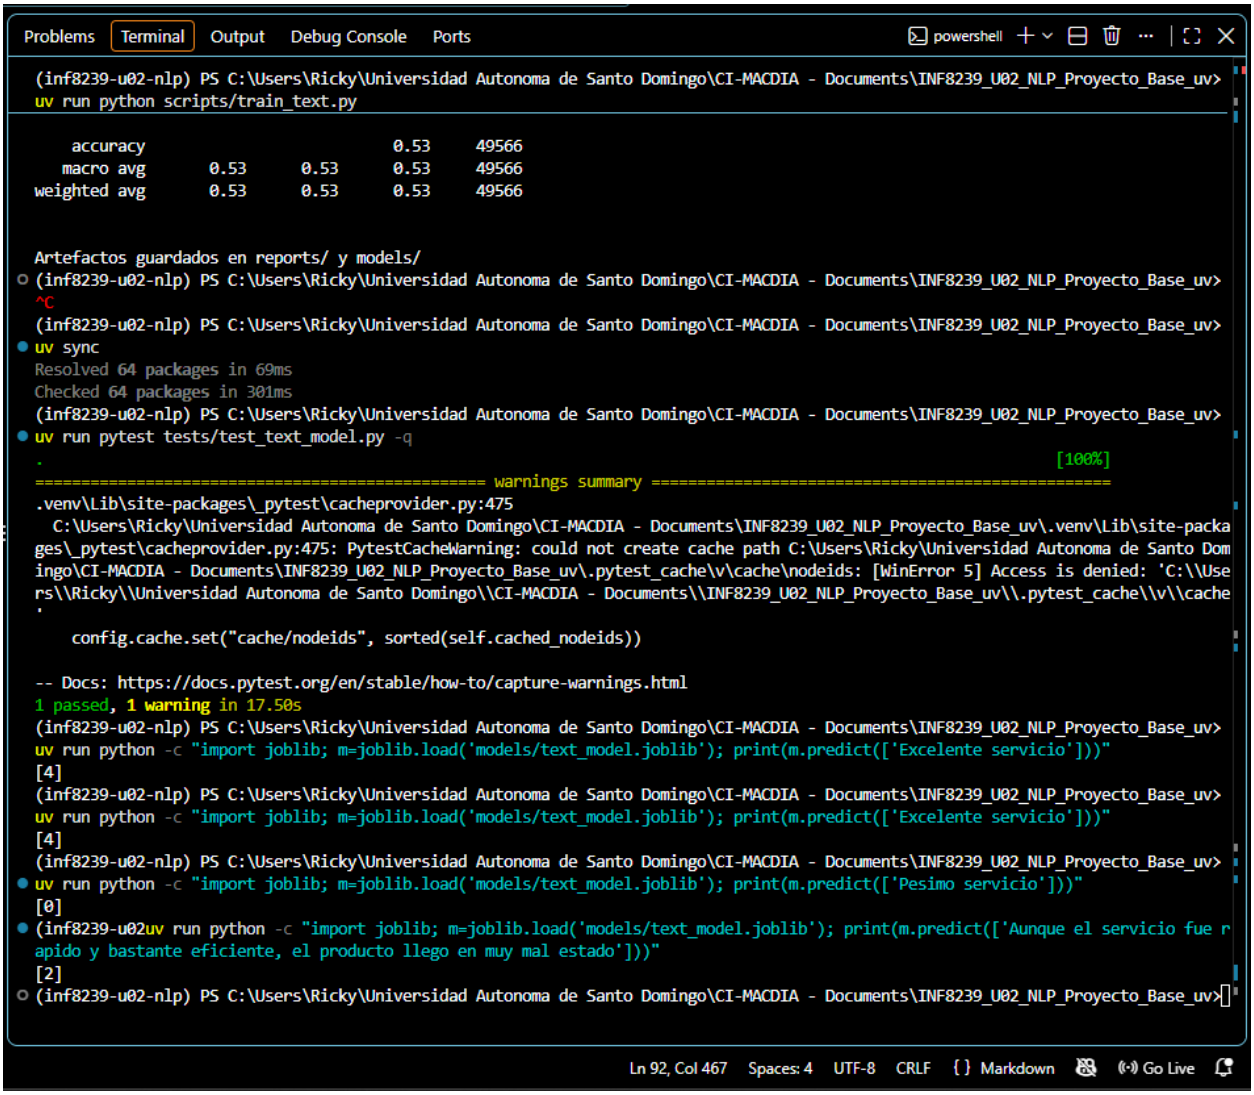
Una reseña de 4 estrellas (Clase 3) habitualmente expresa satisfacción general, pero incluye una objeción sutil o sugerencia de mejora (por ejemplo: *"El producto funciona excelente, pero el embalaje vino ligeramente aplastado"*). Al ser clasificada como 5 estrellas (Clase 4 / perfección), el sistema asume que la experiencia fue impecable y **filtra o descarta el comentario de los paneles de control de calidad**.

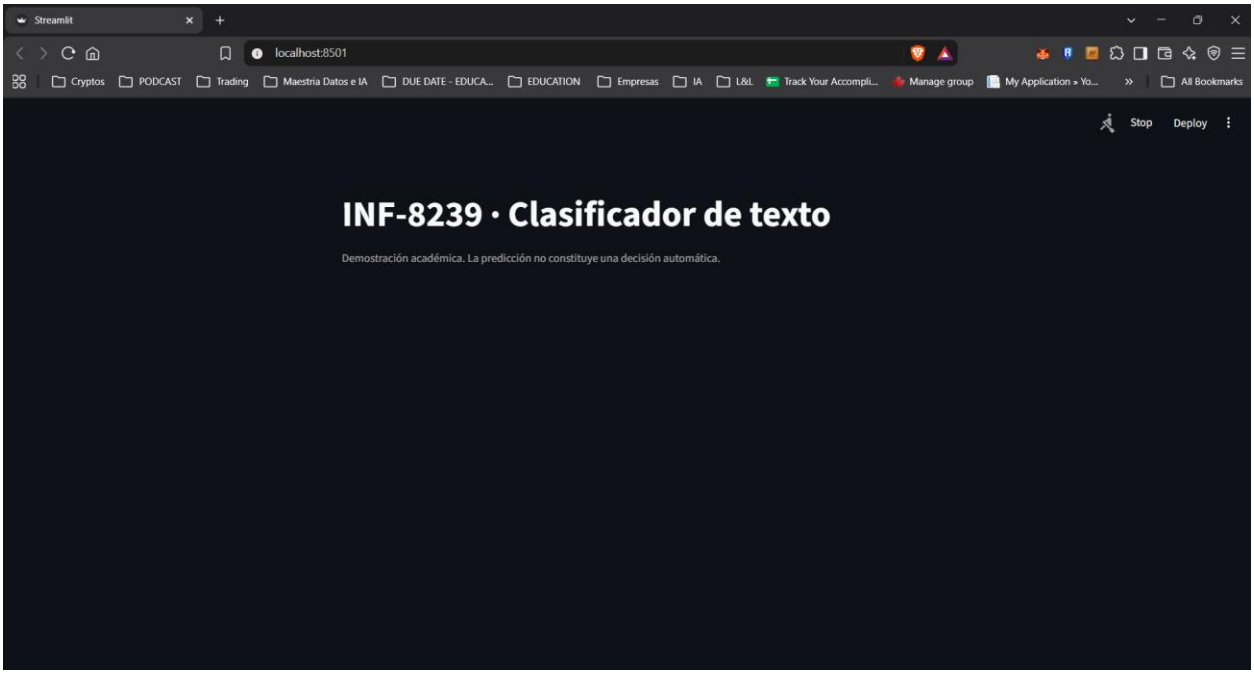
2. **Falso sesgo de optimismo en métricas de satisfacción (NPS / CSAT):**

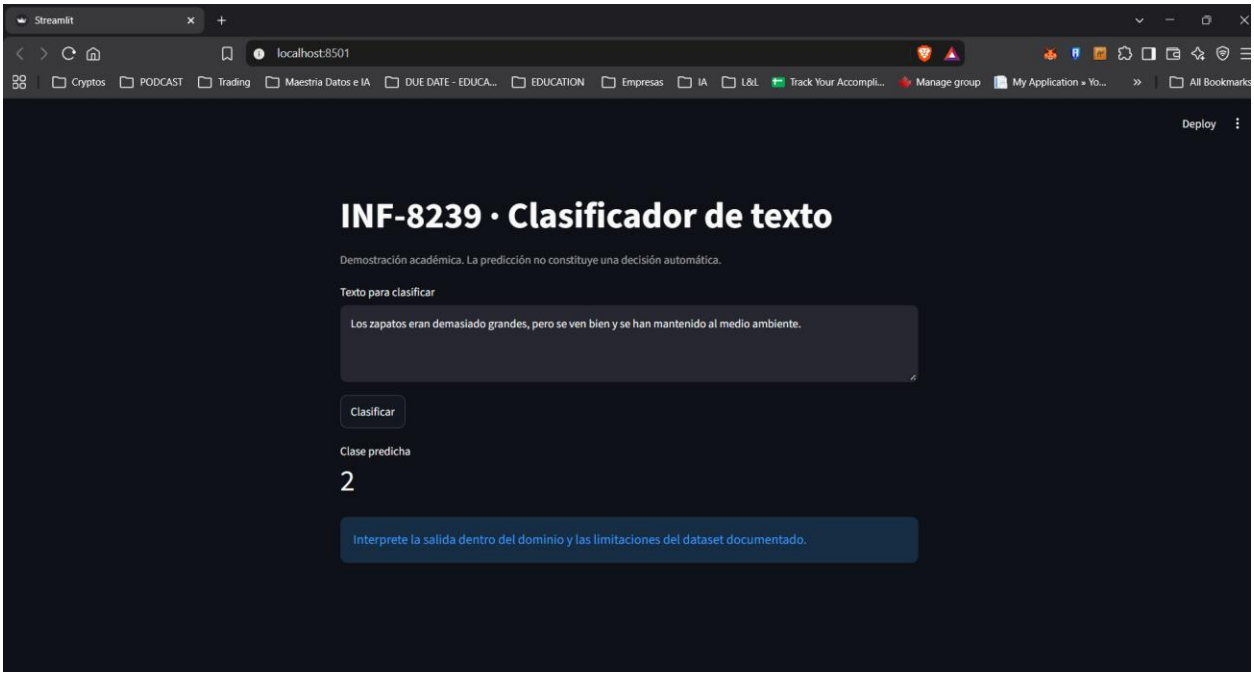
Al transformar artificialmente casi 3,000 opiniones de 4 estrellas en calificaciones máximas de 5 estrellas, la empresa sobrestima el nivel de deleite del cliente. Esto genera complacencia estratégica, ya que se asume que no existen fricciones en la experiencia de compra.

3. **Pérdida de oportunidad de retención y fidelización:**

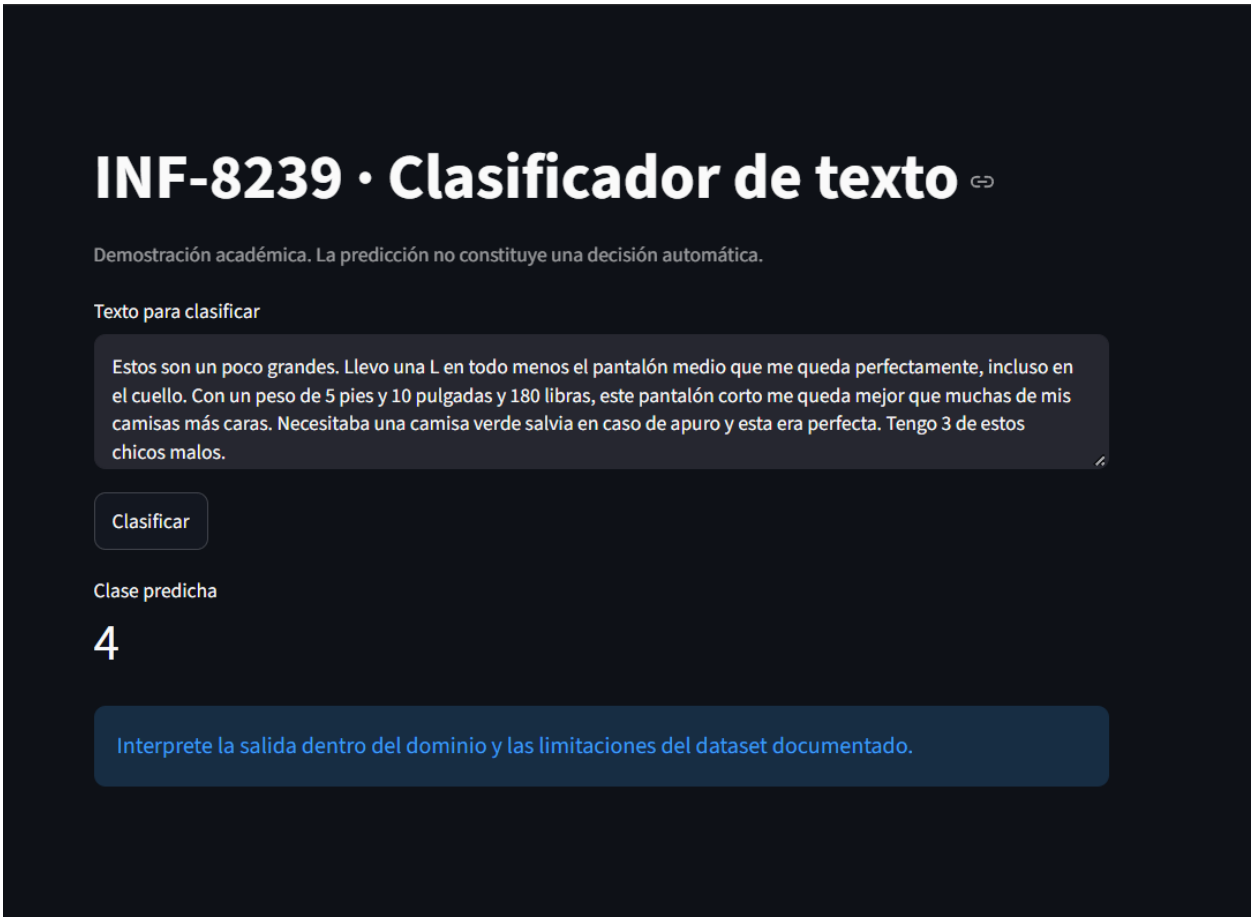
Los clientes que otorgan 4 estrellas están a un paso de la lealtad absoluta si se atienden sus observaciones menores. Omitir estos comentarios impida que el equipo de atención al cliente actúe proactivamente para solucionar pequeños inconvenientes antes de que escalen a valoraciones negativas (1 o 2 estrellas) en futuras compras.


Problems
Terminal
Output
Debug Console
Ports
powershell
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
uv run python scripts/train_text.py
accuracy 0.53 49566
macro avg 0.53 0.53 0.53 49566
weighted avg 0.53 0.53 0.53 49566
Artefactos guardados en reports/ y models/
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
^C
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
uv sync
Resolved 64 packages in 69ms
Checked 64 packages in 301ms
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
uv run pytest tests/test_text_model.py -q
. [100%]
warnings summary
.venv\Lib\site-packages_pytest\cacheprovider.py:475
C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.venv\Lib\site-packages_pytest\cacheprovider.py:475: PytestCacheWarning: could not create cache path C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv\.pytest_cache\v\cache\nodeids: [WinError 5] Access is denied: 'C:\\Users\\Ricky\\Universidad Autonoma de Santo Domingo\\CI-MACDIA - Documents\\INF8239_U02_NLP_Proyecto_Base_uv\\.pytest_cache\\v\\cache'
config.cache.set("cache/nodeids", sorted(self.cached_nodeids))
-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
1 passed, 1 warning in 17.50s
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
uv run python -c "import joblib; m=joblib.load('models/text_model.joblib'); print(m.predict(['Excelente servicio']))"
[4]
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
uv run python -c "import joblib; m=joblib.load('models/text_model.joblib'); print(m.predict(['Excelente servicio']))"
[4]
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
uv run python -c "import joblib; m=joblib.load('models/text_model.joblib'); print(m.predict(['Pesimo servicio']))"
[0]
(inf8239-u02uv run python -c "import joblib; m=joblib.load('models/text_model.joblib'); print(m.predict(['Aunque el servicio fue rapido y bastante eficiente, el producto llego en muy mal estado']))"
[2]
(inf8239-u02-nlp) PS C:\Users\Ricky\Universidad Autonoma de Santo Domingo\CI-MACDIA - Documents\INF8239_U02_NLP_Proyecto_Base_uv>
Ln 92, Col 467
Spaces: 4
UTF-8
CRLF
{ } Markdown
Go Live


Streamlit
localhost:8501
Cryptos
PODCAST
Trading
Maestria Datos e IA
DUE DATE - EDUCA...
EDUCATION
Empresas
IA
L&L
Track Your Accompli...
Manage group
My Application » Yo...
All Bookmarks
Stop
Deploy
INF-8239 · Clasificador de texto
Demostración académica. La predicción no constituye una decisión automática.


Streamlit
localhost:8501
Cryptos
PODCAST
Trading
Maestria Datos e IA
DUE DATE - EDUCA...
EDUCATION
Empresas
IA
L&L
Track Your Accompli...
Manage group
My Application » Yo...
All Bookmarks
Deploy
INF-8239 · Clasificador de texto
Demostración académica. La predicción no constituye una decisión automática.
Texto para clasificar
Los zapatos eran demasiado grandes, pero se ven bien y se han mantenido al medio ambiente.
Clasificar
Clase predicha
2
Interprete la salida dentro del dominio y las limitaciones del dataset documentado.


INF-8239 · Clasificador de texto
Demostración académica. La predicción no constituye una decisión automática.
Texto para clasificar
Me gustó la bota. Desafortunadamente se sienten un poco baratos. Medir un tamaño/tamaño y medio
Clasificar
Clase predicha
3
Interprete la salida dentro del dominio y las limitaciones del dataset documentado.


INF-8239 · Clasificador de texto
Demostración académica. La predicción no constituye una decisión automática.
Texto para clasificar
Estos son un poco grandes. Llevo una L en todo menos el pantalón medio que me queda perfectamente, incluso en el cuello. Con un peso de 5 pies y 10 pulgadas y 180 libras, este pantalón corto me queda mejor que muchas de mis camisas más caras. Necesitaba una camisa verde salvia en caso de apuro y esta era perfecta. Tengo 3 de estos chicos malos.
Clasificar
Clase predicha
4
Interprete la salida dentro del dominio y las limitaciones del dataset documentado.